## Table des matières

I	Leçons	3
1	Exemples de méthodes et outils pour la correction des programmes.  1 Terminaison	<b>5</b> 5
	2 Correction partielle	7
	3 Correction	8
	4 Outils pratiques	10
2	Paradigmes de programmation : impératif, fonctionnel, objet. Exemples et applications.	11
	1 La programmation impérative	11
	2 Programmation fonctionnelle	12
	3 Programmation orientée objet	13
	4 Dans la vraie vie?	14
3	Tests de programme et inspection de code.	15
	1 Introduction	15
	2 Tests en boîtes noires	16
	3 Tests en boite blanche	17
	4 Pratiques pour éviter d'avoir à déboguer	18
4	Principe d'induction	19
•	1 Principe	19
	2 Structures de données inductives	22
	3 Ensembles inductifs	23
5	Implémentations et applications des piles, files et files de priorité	25
3	1 Les piles	25
	2 Les files	26
	3 File de priorité	27
	4 Applications aux graphes	28
	5 Applications systèmes	29
	5 Applications systemes	29
6	Implémentations et applications des ensembles et des dictionnaires	30
	1 Dictionnaire : type abstraits et motivation	30
	2 Implémentation	30
	3 Ensembles	33
	4 Application	33
7	Accessibilité et chemins dans un graphe. Applications	35
	1 Definition	35
	2 Accessibilité	36
	3 Plus court chemin	38

8	Algo	orithme de tri. Exemple, Complexité et Applications	41
	1	Introduction	41
	2	Tri quadratiques	42
	3	Tri efficace	43
	4	Application	45
9	Algo	orithmique du texte. Exemples et applications.	47
	1	Encodage et compression	47
	2	Comparaison	49
	3	Recherche de motifs	50
10	Arbı	res : représentations et applications	53
	1	Généralités sur les arbres	53
	2	Représentation informatique	54
	3	Application	
11	Exe	mples d'algorithmes d'approximation et d'algorithmes probabilistes	59
	1	Algorithmes probabilistes	59
	2	Algorithmes d'approximation	
	3	Algorithmes d'approximation probabilistes	63

## Première partie Leçons

## Exemples de méthodes et outils pour la correction des programmes.

Auteur e s: Emile Martinez

Références :

**Commentaire 1.1** *Ici correction est pris majoritairement dans le sens «est correct» et non dans le sens de «corriger», à savoir rectifier car c'est souvent dans ce sens là qu'on parle de correction de programme.* 

**Commentaire 1.2** On se concentre ici surtout sur les outils théoriques, en estimant que le terme «méthode» de l'intitulé de la leçon laisse penser que c'est sur ceux-là qu'il faut se concentrer

La conjecture de Syracuse est un problème ouvert de Mathématiques :

La suite 
$$u$$
 définie par : 
$$\begin{cases} u_0 = a \in \mathbb{N}^* \\ u_{n+1} = \begin{cases} \frac{u_n}{2} & \text{si } u_n \text{ est pair} \\ 3u_n + 1 & \text{sinon} \end{cases}$$
 (toujours = pour tout  $a \in \mathbb{N}^*$ )

Cela revient à savoir si l'algorithme

```
Algorithme 1.1 : Syracuse(a) \begin{array}{c} u \leftarrow a \\ \textbf{tant que } \underline{u} \text{ est une nouvelle valeur faire} \\ \textbf{si } \underline{u} \text{ est pair alors} \\ u \leftarrow \frac{u}{2} \\ \textbf{sinon} \\ u \leftarrow 3u + 1 \\ \textbf{retourner } u \end{array}
```

renvoie toujours 1, 2 ou 4.

**Commentaire 1.3** C'est un exemple fleuve qui nous permettra d'illustrer toutes les notions autour de la correction et leur non trivialité

#### 1 Terminaison

Une première question est de savoir si Syracuse finit (ne boucle pas à l'infini) sur toute entrée.

Définition 1.1 Prouver la terminaison d'un algorithme revient à prouver que sur toute entrée il termine

Remarque 1.1 On se limite parfois aux entrées valides (pour Syracuse,  $a \in \mathbb{N}^*$  par exemple)

#### Exemple 1.1

```
Tant que a > 0:
a = a - 1
```

Termine sur tout entrée si on n'autorise pas a à valoir  $+\infty$ , sinon ne termine pas sur toute entrée.

**Définition 1.2** Un variant est une fonction des variables, à valeurs dans  $\mathbb N$  qui décroit streitement :

- à chaque passage dans la boucles pour les algorithmes itératifs
- à chaque appel récursif pour les algorithmes récursifs.

#### Exemple 1.2

```
Algorithme 1.2 : \operatorname{pgcd}(a,b)

tant que \min(a,b)>0 faire

\begin{array}{c|c} \operatorname{si} a < b \text{ alors} \\ \hline b \leftarrow b-a \\ \hline \end{array}
\begin{array}{c|c} a \leftarrow a-b \\ \end{array}

retourner \max(a,b)
```

La fonction pgcd(a,b) qui calcule le pgcd de a et b pour  $a,b \in \mathbb{N}$  admet comme variant a+b (qui est en effet toujours positif, et décroit à chaque fois)

Commentaire 1.4 Nous réutiliserons plusieurs fois cet exemple du pgcd

**Proposition 1.1** Si une boucle a un variant de voucle, alors elle s'éxecute un nombre fini de fois. De même pour un algorithme récursif.

**Exemple 1.3** pgcd(a,b) termine pout tout  $(a,b) \in (\mathbb{N}^*)^2$ 

Remarque 1.2 Si un algorithme termine sur toute entrée, il existe toujours un variant, mais il peut être difficile à trouver (ou à prouver)

**Commentaire 1.5** Il suffit de prendre comme variant le nombre d'étapes de calcul restantes en focntion de l'état de la mémoire

#### Exemple 1.4

## $\begin{cases} \text{On d\'efinit } ack(n,m) \text{ pour } n,m \in \mathbb{N} \text{ par} \\ ack(0,m) = m+1 \\ ack(n,0) = ack(n-1,1) \\ ack(n,m) = ack(n-1,ack(n,m-1)) \end{cases}$

```
Algorithme 1.3 : \operatorname{ack}(n,m)

si n=0 alors
retourner m+1

sinon
si m=0 alors
retourner \operatorname{ack}(n-1,m)

sinon
retourner \operatorname{ack}(n-1,ack(n,m-1))
```

Il n'est pas immédiat que ack termine.

Définition 1.3 On dit qu'un ordre est un ordre bien fondé si toute suite décroissante est stationnaire

**Exemple 1.5** N avec l'ordre naturel est bien fondé

Proposition 1.2 Les ordres produit et lexicographiques d'ordre bien fondés sont bien fondés

**Exemple 1.6** Un ordre total sur un ensemble fini est bien fondé, donc l'ordre alphabétique est bien fondé (c'est un ordre lexicographique)

Définition 1.4 On étend alors la définition du variant aux fonctions à valeurs dans un bon ordre.

Proposition 1.3 La propriété 1.1 reste valide avec notre définition étendue du variant

**Exemple 1.7** Pour ack, (n,m) est un variant dans  $\mathbb{N}^2$  avec l'ordre lexicographique, donc ack termine

#### 2 Correction partielle

Une autre question pour Syracuse est de savoir si on peut tomber sur un autre cycle que 1,2,4 et donc renvoyer autre chose que 1,2 ou 4.

**Définition 1.5** On appelle **spécification** d'un algorithme deux propriétés  $P_1$  sur les entrées (précondition) et  $P_2$  sur les sorties (post-condition)

**Exemple 1.8** Pour Syracuse,  $P_1 : \ll a \in \mathbb{N} \gg \text{et } P_2 : \ll \text{Syracuse}(a) \in \{1, 2, 4\} \gg a$ 

**Définition 1.6** On dit qu'un algorithme est **partiellement correct** si pour toute entrée vérifiant la pré-condition, si l'algorithme termine, la sortie vérifie la post-condition.

**Exemple 1.9** L'algorithme de l'exemple 1.2 est partiellement correct si la pré-condition est  $\ll a \in \mathbb{N}, b \in \mathbb{N}$  et la post-condition  $\ll pgcd(a,b)$  renvoie le PGCD de a et de  $b\gg$ 

#### I Correction partielle des algorithmes impératifs

Pour prouver la correction partielle des langages impératifs, on utilise un invariant de boucle.

Définition 1.7 Un invariant de boucle est une propriété qui est vrai avant la boucle, et si elle est vraie quand on commence un tour de boucle, alors elle l'est quand on le finit.

**Proposition 1.4** Si un invariant de boucle est valide, alors il est vrai après la boucle, et la condition d'arrêt de la boucle est fausse.

**Exemple 1.10** Pour pgcd,  $\ll PGCD(a,b) = PGCD(a_0,b_0) \gg où a_0$  et  $b_0$  sont les valeurs initiales de a et b, est un invariant valide.

A la fin de l'exécution, on a donc  $\min(a,b)=0$  et  $PGCD(a,b)=PGCD(a_0,b_0)=PGCD(\min(a,b),\max(a,b))=PGCD(0,\max(a,b))=\max(a,b)$ . D'où l'assertion de l'exemple 1.9

#### II Correction partielle des algorithmes récursifs

Commentaire 1.6 On ne présente souvent pas la correction partielle des algorithmes récursifs, en se contentant de la correction totale directement. Néanmoins on présente quand cela, car cela illustre très bien la manière de raisonner quand on veut coder en récursif (et que tout est vrai)

Principe 1.1 Pour prouver la correction partielle d'un algorithme récursif, on vérifie que si

- la pré-condition est vérifiée
- . alors
  - on ne fait que des appels récursifs où les arguments vérifient la pré-condition
  - Si la post-condition des appels récursifs est vérifiée, alors celle de notre appel est vérifiée

**Théorème 1.1** Si le principe 1.1 est respecté, alors l'algorithme est partiellement correct.

**Exemple 1.11** exp(a,n) pour  $a, n \in \mathbb{N}$  renvoie  $a^n$ .

```
Algorithme 1.4 : \exp(a, n)

si n = 0 alors
| retourner 1

sinon
| x = \exp(a, n)

si n = \exp(a, n)

si n = \exp(a, n)

retourner n = n = n

sinon
| retourner n = n = n
```

Précondition : «a est un flottant et n un entier».

Postcondition:  $exp(a,n) = a^n$ .

Alors, la pré-condition est valide à chaque appel, et comme  $a^n=a^{\lceil n\rceil}*a^{\lfloor n\rfloor}$ , le principe 1.1 est respecté dans tous les cas donc l'algorithme est partiellement correct.

#### 3 Correction

La conjecture de Syracuse dit donc que notre fonction Syracuse termine, et quand elle termine est correcte (i.e. partiellement correcte).

#### I Cas général

**Définition 1.8** Quand un programme termine sur toute entrée valide et est partiellement correct, on dit qu'il est correct, ou encore totalement correct.

#### Exemple 1.12

#### **Algorithme 1.5**: fusion( $L_1$ , $L_2$ )

```
\begin{tabular}{ll} res &\leftarrow [] \\ i,j &\leftarrow 0 \\ & \textbf{tant que} \quad \underline{i < |L_1| \text{ et } j < |L_2|} \quad \textbf{faire} \\ & \quad \textbf{si} \quad \underline{L_1[i] < L_2[j]} \quad \textbf{alors} \\ & \quad | \quad res.ajouter(L_1[i]) \\ & \quad | \quad i \leftarrow i+1 \\ & \textbf{sinon} \\ & \quad | \quad res.ajouter(L_2[j]) \\ & \quad | \quad j \leftarrow j+1 \\ \\ & \quad \textit{Ajouter le reste de $L_1$ et de $L_2$ à $res$} \\ & \quad \textbf{retourner } res \\ \end{tabular}
```

#### **Algorithme 1.6**: $tri\_fusion(L)$

**Developpement ??** Correction totale de tri\_fusion.

Néanmoins, ce n'est pas toujours facile. La conjecture de Syracuse est toujours un problème ouvert. Et c'est parfois même pire.

**Théorème 1.2** La correction partielle et la terminaison sont indécidables.

**Developpement ??** Preuve du théorème 1.2

#### II Cas des algorithmes récursifs

Dans le cas des algorithmes récurifs, on fait régulièrement la correction totale directement.

**Proposition 1.5**  $SI(E, \preceq)$  est un ordre bien fondé, alors toutes parties non vides à un élément minimal (plus grand que personne)

**Théorème 1.3** Soit  $(A, \preceq)$  un ensemble muni d'un ordre bien fondé et  $\mathcal{P}$  une propriété sur A, alors  $\forall x \in A, \ (\forall y \in A, \ y \preceq A \ \Rightarrow \ \mathcal{P}(y) \Rightarrow \mathcal{P}(x)) \ \Rightarrow \ \forall x, \ \mathcal{P}(x)$ 

Remarque 1.3 Cela étend le principe de réccurence forte sur N

L'ordre bien fondé nous donne alors le variant et la propriété l'invariant. On montre alors la terminsaison et la correction partielle en même temps.

**Exemple 1.13** Dans l'exemple 1.2, la propriété  $\mathcal{P}(n)$  :  $\ll \exp(a,n) = a^n \gg v$ érifie les bypothèses du théorème 1.3. Donc,  $\forall n, \exp(a,n) = a^n$ , et ce pour tout  $a \in \mathbb{N}$ 

**Commentaire 1.7** Ici on suppose que  $\exp(a,n)=a^n$  veut dire que exp termine et renvoie  $a^n$ 

#### 4 Outils pratiques

- \* Typer : Le fait d'utiliser un typage fort comme en OCamL permet d'éviter beaucoup d'erreurs bêtes
- \* Programmer défensivement en utilisant la bibliothèque assert.h permet de vérifier qu'à un moment donné du code, les hypothèses (ou les invariants) sont satisfaits (et pas seulement une erreur aléatoires parmi 1000 lignes)
- \* Faire des test tout au long de la programmation, en utilisant au maximum la modularité, pour détecter le plus tôt possible les erreurs.
- \* Utiliser des logiciels comme GDB ou valgrind pour détecter les fuites mémoires, ou l'inspecter au cours du programme.
- \* Commentez! C'est primordial pour déclarer la spécification des fonctions et rendre le code compréhensible, donc déboguable.

Commentaire 1.8 On pourrait développer cette partie également en parlant plus longuement des tests (cf lecon 3) qui est un autre type d'outils pour éprouver la correction d'un programme. Mais ca nous emmène un peu loin pour cette leçon (il faut bien faire des choix)

# Paradigmes de programmation : impératif, fonctionnel, objet. Exemples et applications.

Auteur e s: Emile Martinez

Références:

Programmer, c'est mettre en relation un cahier des charges et des instructions compréhensibles par la machine.

**Définition 2.1** Un paradigme de programmation définit la façon d'approcher la programmation informatique.

Suivant le contexte il en existe plusieurs que nous verrons ici.

### 1 La programmation impérative

C'est la plus classique.

Définition 2.2 La programmation impérative consiste à donner une suite d'instructions, chacune ayant pour seul effet de modifier l'état du programme (la mémoire, la valeur des variables, l'endroit où on en est etc...).

Remarque 2.1 Ainsi, dans la programmation impérative, il n'existe pas de valeurs de retour. Si on en veut une, il faut écrire la valeur que l'on veut dans la mémoire.

Remarque 2.2 Informellement, programmer impérativement, c'est utiliser des variables, des affectations, des tableaux, des boucles for et while, etc...

**Exemple 2.1** La majorité du code en python est impératif

```
 \begin{vmatrix} x = 1 \\ y = x + 3 \\ while (x != y): \\ print(y) \\ y -= 1 \end{vmatrix}
```

Ce programme écrit 1 dans la case mémoire de x, puis y accède pour écrire 4 dans celle de y, puis écrit la valeur de y dans l'espace mémoire dédié à l'affichage, etc...

Remarque 2.3 Impératif est pris ici dans son sens courant (en informatique). Une autre définition d'impératif est qu'on dit exactement ce que la machine doit faire (ex : l'assembleur), ce qui s'opose alors au déclaratif (comme SQL). Mais cette notion est à degré (dans tous langage il y a une marge plus ou moins grande pour la machine) et n'est pas nécessairement celle à laquelle on pense quand on pense à de la programmation impérative (même si les deux sont très liées).

#### 2 Programmation fonctionnelle

Définition 2.3 La programmation fonctionnelle consiste à composer le programme de fonctions (au sens mathématiques), et de récupérer la valeur de retour.

Les changements d'état ne peuvent pas être représentés par des évaluations de fonctions, donc la programmation fonctionnelle ne les admet pas. On dit que les structures de données fonctionnelles sont immuables.

```
Exemple 2.2 let max(x,y) = if x > y then x else y (fonction de type int*int -> int)
```

Informellement, programmer en fonctionnel, c'est considérer les fonctions comme des objets comme les autres, et n'avoir que des structures de données immuables.

**Remarque 2.4** Un argument d'une fonction ou la valeur de retour d'une fonction peut être une fonction. C'est ce que l'on appelle la programmation d'ordre supérieure.

**Définition 2.4** La curryfication est la transformation d'une fonction à plusieurs arguments en une fonction à un argument qui retourne une fonction sur le reste des arguments

**Exemple 2.3** On peut transformer la fonction max de l'exemple 2.2 en la fonction let  $\max x y = \text{if } x > y \text{ yhen } x \text{ else } y \text{ de type int } -> \text{int } -> \text{int}$ 

**Exemple 2.4** Si, sur l'exemple 2.3, on veut que max puisse comparer des éléments sur lesquels on ne connait pas l'ordre, on peut en faire une fonction d'ordre supérieur en lui fournissant une fonction de comparaison :

let  $max\ compar\ x\ y = if\ compar\ x\ y\ then\ x\ else\ y\ de\ type\ ('a -> 'a -> bool)\ -> 'a\ -> 'a$  On a alors

max (fun x y -> x > y) qui calcule le max

 $\max$  (fun x y -> x > y) 3 qui est une fonction de type int -> int renvoyant le maxmimum de son argument et 3

max (fun x y -> x < y) qui calcule le min

Remarque 2.5 La puissance du fonctionnel vient de la récursivité

#### 3 Programmation orientée objet

#### I Obtenir de la modularité

Définition 2.5 Une classe est un ensemble de types de données appelés attributs et de fonction appelées méthodes.

Un **objet** est un représentant d'une classe. C'est un espace en mémoire contenant les valeurs des différentes attribut, les méthodes étant communes à tous les objets.

#### Exemple 2.5

```
class Noeud:
    def __init__(self, x):
        self.valeur = x
    def afficher(self):
        print(self.valeur)
    def est_egal(self, autre):
        return self.valeur == autre.valeur
a = Noeud(5)
a.afficher()
```

Ici Noeud est une classe, valeur un attribut de la classe Noeud, afficher et est\_egale des méthodes de la classe Noeud et a un objet (représentant) de la classe Noeud

Définition 2.6 La programmation orienté objet consiste à utiliser des classes et des objets de ces classes quand on programme.

Remarque 2.6 Une utilisation massive des classes et de permettre de la modularité : on peut avoir une interface entre un type abstrait et son utilisation, rendant l'utilisation et la structure implémentant le type indépendant.

**Exemple 2.6** En python, le package numpy propose les objets numpy.array que l'on crée via la commande a = numpy.array([...]). Un tel objet possède des attributs comme sa taille (a.size) mais aussi des méthodes tq a.sort()). Cette classe implémente des tableaux de taille fixe et de nombreuses méthodes dessus. On peut les utiliser en ne comprenant rien à comment elles fonctionnent, seulement ce qu'elles font, mais on peut aussi les réimplenter sans rien changer à l'utilisation de ces tableaux par des millions de personnes.

#### Il Pour résoudre un problème

Une autre utilité de la programmation orienté objet, et de représenter un problème avec ses différents objets que l'on fera intéragir entre eux.

**Exemple 2.7** Sur l'exemple 2.5, on peut rajouter la classe Arbre contenant des noeuds.

```
class Arbre:
    def __init__(self, n, liste_arbre):
        self.noeud = n
        self.fils = liste_arbre
    def afficher(self):
```

```
n.afficher()
for x in self.fils:
x.afficher()
```

#### 4 Dans la vraie vie?

#### I Le multiparadigme

Dans la vraie vie, la plupart des langages de programmation implémente plusieurs paradigmes. En effet, python, comme C ou Ocaml, permettent de faire des boucles while, de faire des tableaux, de faire des structures et des fonctions récurisves, et même les fonctions d'ordre supérieur dans une certaine mesure.

On appelle cela le multiparadigme. Néanmoins, certains langages sont plus adapatés à certains paradigmes, eux-mêmes plus adaptés à certaines contraintes.

Des langages comme C, C++, Fortran, python, Java sont des langages impératifs, quand Haskell, ML, OcamL sont fonctionnels. De plus, python, C++ sont orientés objets.

#### II Comparaison des paradigmes

- \* Pour des structures récursives comme des arbres (ou des graphes peu denses), le paradigme fonctionnel est approprié
- ★ Le paradigme fonctionnel offre également élégance et lisibilité au code, avec moins d'instructions «superflues»
- \* Le caractère intrinséquement modulaire et sans effet de vord le rend aussi plus facile à tester et sécuriser : C'est en OcamL (en Coq) qu'est implémenté CompCert, un compilateur C vérifié.
- \* La programmation impérative est beaucoup plus proche de la machine et rend donc la compilation plus simple, et le développement intelligent potentiellement plus efficace.
- \* Il est aussi très performant pour des structures de données séquentilles et des accès «aléatoires» à des données. Par exemple représenter une matrice, en faire des multiplications, etc... paraît beaucoup plus simple en C qu'en OcamL.

Exercice 2.1 Implémenter un tas min en C et en OCamL

- \* L'orienté objet est quant à lui de plus haut niveau et repose souvent sur d'autres paradigmes plus bas niveau.
- \* Il est souvent utilisé pour représenter des situtations complexes grâce à sa modularité

Exercice 2.2 Implémenter les classes représentant un personnage de jeu vidéo, ses objets, ses compétences, etc...

#### III Et SQL?

Il existe néanmoins bien d'autres paradigmes, comme par exemple le paradigme logique, où seul le résultat est présenté par le code, et non la manière de l'obtenir. C'est par exemple le cas du SQL pour les bases de données, où l'exécution n'est pas dicté par la requête, seul son sens l'est, laissant le SGBD se charger du déroulement.

## Tests de programme et inspection de code.

Auteur-e-s: Emile Martinez, Malory Marin

Références:

#### 1 Introduction

#### I Qu'est-ce qu'un test

Tester est un anglicisme pour le mot français essayer (ou éprouver). Me soumettant à la folie anglomane ambiante je garderai ce mot, soucieux de ma cohérence avec le monde extérieur.

Définition 3.1 Tester un programme consiste à essayer d'y trouver des erreurs

Remarque 3.1 On ne cherche pas ici à prouver directement que le programme est correct, mais à prouver qu'on n'arrive pas à se rendre compte qu'il est incorrect.

#### II Données de tests

Définition 3.2 Une donnée de test est un couple (valeur d'entrée, valeur de sortie), où à l'évidence, le deuxième élément représente la valeur de sortie quand la fonction est appelée sur le premier élément.

**Définition 3.3 Un jeu de données de test** (ou jeu de tests) est alors un ensemble de tels couples, permettant de vérifier la validité du programme sur certaines entrées.

Remarque 3.2 Certaines sorties (attendues) peuvent être des erreurs.

**Exemple 3.1** Un jeu de tests pour une fonction calculant le pgcd peut être  $\{((1,2),1),((-3,6),3),((0,0),0),((2,2.45),Erreur de type)\}$ 

#### III Types de tests

Il existe deux types de tests :

- Les tests en boites noires : On ne connait pas le code de la fonction, on peut simplement l'appeler.
- Les tests en boites blanches : On connaît le code et on génère un jeu de test en fonction.

#### 2 Tests en boîtes noires

#### I Caractéristiques

Pour un test en boîtes noires, comme on ne connait pas le code, il faut tester beaucoup de données. Idéalement, toutes, mais cela se trouve souvent impossible.

**Exemple 3.2** On peut tester toutes les valeurs d'une fonction qui implémente une fonction booléenne mais pas celles de notre fonction calculant le pgcd de deux nombres

Viennent alors deux problèmes : Générer suffisament de données d'entrées et effectuer le test suiffisament rapidement.

#### II Générer des données d'entrée

Dans de nombreux cas, ne pouvant pas essayer toutes les données d'entrées, on va devoir faire des choix.

**Idée 3.1** La première approche consisterait à générer des valeurs aléatoires dans un domaine, et espérer en prendre suffisamment pour que cela fonctionne.

**Principe 3.1** Une approche plus maline, à partitionner le domaine, puis à appliquer l'approche naïve sur chaque domaine.

**Exemple 3.3** Pour le calcul de pgcd(a,b), on peut parititionner le domaine d'entrées en comparant a, b, et 0, (avec donc 6 domaines : a <= 0 <= b, 0 <= a <= b, 0 <= a <= 0, b <= 0 <= a)

Remarque 3.3 On se contente souvent de prendre un seul test par classe.

Remarque 3.4 Le choix du partitionnement est arbitraire et doit donc être fait suivant la manière d'approcher le problème

Une fois cela fait, il est très commun que les erreurs puissent venir des cas limites.

**Principe 3.2** On essaye alors de se placer au limites des domaines, et de vérifier spécifiquement ces cas là.

**Exemple 3.4** Pour l'exemple précédent, on testerai les cas d'égalité : 0 <= a = b, a = 0 = b, a = 0 <= b etc... (en effet par exemple, le cas 0, 0 est différent des autres, la valeur pouvant être  $+\infty$  ou 0 suivant les définitions).

#### III Utiliser les caleurs de sorties efficacement

Néanmoins, maintenant que l'on a les valeurs d'entrées, il faut pour avoir notre jeu de tests avoir également les valeurs de sorties.

**Exemple 3.5** si l'on veut générer la sortie du pgcd sur des entrées que l'on a pris au hasard, il faut connaitre déjà le pgcd. Quel intérêt d'avoir notre fonction alors si on a déjà une fonction qui le fait

On a alors plusieurs méthodes :

- 1. Générer un jeu de tests à la main
- 2. Utiliser un programme moins performant mais que l'on sait correct.

**Exemple 3.6** Si on calcule le pgcd par soustraction successives, on peut tester en calculant le pgcd en testant tous les nombres inférieurs à a et a garder le plus grand qui divise a et b.

3. Ne pas calculer la réponse mais simplement vérifier que la réponse fourni est correcte.

**Exemple 3.7** Si on a un programme qui nous donne la décomposition en facteurs premiers d'un nombre, il nous suffit de tester la primalité de chaque sortie et de vérifier que leur produit fait l'entrée.

**Exemple 3.8** Si on a un algorithme performant effectuant le produit de matrice, on peut :

- 1. Créer à la main quelque petite matrice et faire leur produit pour vérifier que tout fonctionne
- 2. Comparer avec l'algorithme naif du calcul de produit de matrice
- 3. Vérifier de manière probabiliste que le résultat est bien le bon. **Developpement ??** Vérification probabiliste du produit de matrice.

#### 3 Tests en boite blanche

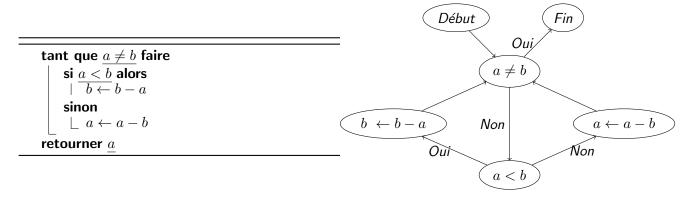
#### I Graphe de flot de contrôle

Pour un test en boîte blanches, on connaît le code, et on va vouloir générer des données d'entrées en fonction de ce code là.

Pour cela, on extrait du code le graphe de flot de contrôle.

Définition 3.4 Le graphe de flot de contrôle est un graphe où chaque boîte contient des lignes de codes, les boites sont reliés si on peut exécuter l'une puis l'autre.

**Exemple 3.9** On prend l'exemple du pgcd pour  $a, b \in \mathbb{N}^*$ 



#### II Utilisation du graphe

On essaye alors de générer un jeu de données qui parcourt une bonne partie du graphe.

Par exemple, un jeu couvrant :

- Tous les nœuds (On veut un jeu de tests tel que tous les tests pris ensemble, chaque nœud du graphe est parcouru au moins une fois).
- Tous les arcs
- Tous les chemins

**Commentaire 3.1** Si on veut aller plus loin, on peut aussi rajouter toutes les conditions décisions, toutes les p utilisations, etc... On peut alors rajouter un exercice proposant de montrer la hiérarchie entre ces tests.

**Exemple 3.10** Sur l'exemple,  $\{((1,1),1),((1,3),3)\}$  ne couvre pas tous les nœuds quand  $\{((1,3),3),((3,1),3)\}$  couvre tous les nœuds et tous les arcs mais pas tous les chemins.

Remarque 3.5 Quand il y a une boucle, tous les chemins peut-être un critère infini. On peut alors se limiter aux chemins d'une certaine taille.

Remarque 3.6 Parfois les critères sont insatisfiables.

Remarque 3.7 Aucun de ces critères ne garantissent la validité d'un algorithme. Elles permettent simplement de vérifier que notre jeu de tests n'est pas trop lacunaire.

Developpement ?? Intérets et insuffisances de ces critères

#### III Test exhaustif de condition

**Idée 3.2** Une autre approche consiste à avoir un jeu qui satisfait ou invalide toutes les conditions de toutes les manières possibles.

#### **Exemple 3.11** On voit l'utilité sur l'exemple suivant :

```
int max(int a, int b){
   if(a > b || a == 500){
     return a;
   else
     return b;
}
```

Pour détecter le problème (que max ne calcule pas le max), il faut des tests où on mets à vrai le premier if à cause de a==500, donc des tests où a vaut 500.

### 4 Pratiques pour éviter d'avoir à déboguer

Dans la pratique, de bonne pratique de code sont très efficace pour éviter de passer trop de temps à debugguer son code.

- ★ Compiler avec -Wall (activant tous les warnings, donnant beaucoup de bugs stupides)
- \* Respecter la ponctuation et éventuellement utiliser un linter (de manière à rendre lisible le code par d'autres personnes)
- \* Faire de la programmation défensive en utilisant assert par exemple

## Principe d'induction

Auteur e s: Emile Martinez

Références:

#### 1 Principe

#### I Definition

```
 \begin{array}{l} \textbf{D\'efinition 4.1 } (\mathcal{B},(f_i)) \text{ est une signature sur } X \text{ si :} \\ & -\mathcal{B} \subset X \text{ (appel\'e cas de base)} \\ & -f_i: X^{\alpha(i)} \to X \text{ appel\'e constructeurs, d'arit\'e } \alpha(f_i) \text{ avec } f_i \text{ injectif et } \Im(f_i) \cap \Im(f_j) = \text{et } \\ \Im(f_i) \cap \mathcal{B} = \text{pour tout } i \neq j \end{array}
```

**Commentaire 4.1** L'intérêt de cette définition est d'être rigoureux. Néanmoins le programme demande de se contenter de présenter des choses proches de ce que l'on rencontrera, or là c'est plus ou moins la version formelle de ce qui se passe en OcamL. Donc meme si ce cadre théorique n'est pas explicitement au programme, sa présence là est justifiée par sa proximité avec OcamL

Remarque 4.1 On se contente souvent de dire que les constructeurs existent, sans donner leur définition. (de même pour les cas de bases, et pour X)

**Exemple 4.1** On prend une constante Z et un constructeur d'arité  $1 \ Succ$ 

**Exemple 4.2** On peut prendre les constructeurs  $\oplus$ ,  $\ominus \otimes$  et  $\otimes$  avec  $\alpha(\oplus) = 2$ ,  $\alpha(\ominus) = 1$  et  $\alpha(\otimes) = 2$  et comme cas de bases  $\mathbb{N}$ .

**Définition 4.2** Un ensemble inductif est définit par une signature  $(\mathcal{B},(f_i))$ :

- 1. Le plus petit ensemble contenant  $\mathcal{B}$  et stable par tous les  $f_i$  (définition par le haut) ou de manière équivalente
- 2.  $\bigcup T_i$  où  $T_0 = \mathcal{B}$  et  $T_{n+1} = T_n \cup \bigcup_i f_i(T_n^{\alpha(f_i)})$  (définition par le bas)

Exemple 4.3 L'ensemble inductif définit par l'exemple 4.1 peut être une définition des entiers naturels

**Exemple 4.4** Exemple : L'ensemble inductif  $A_{simp}$  définit par l'exemple 4.2 est l'ensemble des expressions arithmétiques simplifiées.

Remarque 4.2  $\oplus (1,1) \neq \otimes (1,2) \neq \otimes (2,1)$ . On s'intéresse à l'expression et non au résultat.

Développement ?? Validité de la construction d'un ensemble inductif (remarque 4.1 et définition 4.2)

#### II Induction structurelle

On prendra maintenant  $(\mathcal{B}, (f_i)_{i \in I})$  une signature.

**Proposition 4.1** Soit E un ensemble inductif construit par  $(\mathcal{B}, (f_i))$ 

Alors la donné de fonction  $g_i$  (avec  $\alpha(g_i) = \alpha(f_i)$  et  $\Im(g_i) \subset Dom(g_j)$ ) et de f(b) pour  $b \in \mathcal{B}$  définit une unique fonction f sur E ayant la propriété :

$$\forall i \in I, \forall x_1, \ldots, x_{\alpha(i)} \in X, f\left(f_i(x_1, \ldots, x_{\alpha(i)})\right) = g_i\left(f(x_1), \ldots, f(x_{\alpha(i)})\right)$$

Commentaire 4.2 Cette propriété est fondamentale, et justifie en partie (parce que la il ne faut pas un matching complet mais directement les constructeurs) la bonne définition des fonctions OcamL. D'où d'ailleurs les références à cette propriété dans la suite.

**Exemple 4.5** Sur  $A_{Simp}$ , on peut définir  $eval: A_{Simp} \to \mathbb{N}$  par

- $-- eval(a) = a pour a \in \mathbb{N}$
- $-- eval(\oplus(a,b)) = eval(a) + eval(b)$
- $-- eval(\otimes(a,b)) = eval(a) \times eval(b)$
- $-- eval(\ominus(a)) = -eval(a)$

**Théorème 4.1 (Induction structurelle)** Soit E l'ensemble inductif définit par  $(\mathcal{B}, (f_i)_{i \in I})$ , et  $\mathcal{P}$  une propriété définie pour tout  $x \in E$ .

Alors 
$$\begin{cases} (i) & \forall b \in \mathcal{B}, \mathcal{P}(b) \\ (ii) & \forall i \in I, \forall x_1, \dots, x_{\alpha(i)}, (\forall j, \mathcal{P}(x_j)) \implies \mathcal{P}\big(f_i(x_1, \dots, x_{\alpha(i)})\big) \end{cases}$$

Remarque 4.3 La récurrence est un cas particulier dans le cas de la définition des entiers par l'exemple 4.3

**Exemple 4.6** On montre par induction structurelle que eval(e) pour  $e \in A_{simp}$  est multiple du pgcd des constantes apparaissant dans e

**Définition 4.3** Un ordre bien fondé est un ordre où toute partie non vide admet un élément minimal (plus grand que personne)

Proposition 4.2 L'ordre produit et l'ordre lexicographique d'ordres bien fondés sont bien fondés

**Exemple 4.7**  $\mathbb{N}$  avec l'ordre naturel est bien fondé, donc  $\mathbb{N}^k$  avec l'ordre produit ou lexicographique aussi.

**Théorème 4.2** Soit  $(A, \preceq)$  un ensemble muni d'un ordre bien fondé et  $\mathcal{P}$  une propriété sur A, alors  $\forall x \in A, \ (\forall y \in A, \ y \preceq A \ \Rightarrow \ \mathcal{P}(y) \Rightarrow \mathcal{P}(x)) \ \Rightarrow \ \forall x, \ \mathcal{P}(x)$ 

Remarque 4.4 Cela étend le principe de réccurence forte.

```
Définition 4.4 Soit E l'ensemble inductif défini par (\mathcal{B},(f_i)_{i\in I})
On définit l'ordre structurel \leq_s sur E comme la clôture transitive réflexive de x_j\leq_s f_i(x_1,\ldots,x_{\alpha(i)})
```

```
Proposition 4.3 \leq_s est une relation d'ordre bien fondé
```

**Corollaire 4.1** On peut alors réécrire l'induction structurelle comme une induction sur l'ordre structurelle

**Commentaire 4.3** Si on manque de place, on peut mettre les ordres bien fondés en prérequis (mais alors écrire la formule dans le corollaire)

#### III En OCaml

Commentaire 4.4 On essaye de faire au maximum le lien entre les définitions formelles et OcamL

Syntaxe 4.1 En OcamL on peut créer un type représentant un ensemble inductif avec cette syntaxe :

```
type t = Casdebase1 | Casedebase2 | ...
| Constructeur1 of type11 *type12 * ...
| Constructeur2 of type21 * tpye22 * ...
```

Où :

- Casdebase peut soit être un type déjà défini d'OcamL, soit une constante (nom commençant par une majuscule)
- Constructeur est une étiquette commencée par une majuscule
- typei est est un type OCamL (pouvant contenir t)

**Exemple 4.8** Pour définir les entiers de l'exemple 4.3, on peut écrire

```
type entier = Zero | Succ of entier
```

Syntaxe 4.2 Pour gérer les types, on peut utiliser le filtrage comme pour les listes.

**Exemple 4.9** Pour l'addition sur notre type entier, on peut écrire :

```
| let rec ajouter x y = match y with | Zero -> x | Succ(z) -> ajouter (Succ(x)) z
```

Exemple 4.10 La validité de cette définition vient de la propriété 4.1

#### 2 Structures de données inductives

#### I Les listes chaînées

En OcamL on peut définir des listes d'entier simplement chaînés par

```
type liste = V \mid Cons \ of \ int * liste
```

Ainsi, une liste c'est soit une liste vide, soit un entier et le reste de la liste.

Remarque 4.5 lci V est le cas de base, et Cons le constructeur. Cons est défini sur  $\mathbb{N} \times \{\text{ensemble des listes}\}\$  et non  $\{\text{ensemble des listes}\}\$ . Cela est un raccourci d'OCamL, où en réalité on définit un constructeur pour chaque premier argument, et donc on construit non pas Cons(x,l) mais  $Cons_x(l)$ .

Remarque 4.6 Cela correspond au type int list d'OCamL;-)

Exercice 4.1 Définir inductivement la taille d'une liste chaînée

#### II Les arbres binaires

Exercice 4.2 Définir inductivement la taille d'une liste chaînée.

**Définition 4.5 (Arbre binaires)** Soit A un ensemble. On définit de manière inductive les arbres binaires sur A par :

- l'arbre vide E (cas de base)
- si  $e \in A$  et g et d sont des arbres binaires, alors Noeud(e, g, d) est un arbre binaire.

Implémentation 4.1 Ce qui en OCamL nous donne type 'a arbre = E | Noeud of 'a \* 'a arbre \* 'a arbre

**Exemple 4.11** La hauteur d'un arbre binaire se calcule alors inductivement par

```
let rec hauteur arb = match arb with \mid E -> 0 \mid Noeud(e, g, d) -> 1 + max (hauteur g) (hauteur d)
```

Exercice 4.3 Prouver par induction structurelle la terminaison de la fonction hauteur

Exercice 4.4 Donner la définition inductive de la taille d'un arbre binaire (son nombre d'éléments)

#### III Les arbres généraux

Définition 4.6 Un arbre général est un noeud (la racine) et une liste d'arbre (ses fils)

On voudrait alors définir le type arbre par (pour les arbres d'entier)

```
type arbre = Noeud of int * arbre_liste
```

Il faut alors définir le type arbre\_liste, par

```
type arbre_liste = Vide | Cons of arbre * arbre_liste
```

On remarque que chaque type a besoin de l'autre pour exister. On écrit alors

```
type arbre = Noeud of int * arbre_liste
and type arbre_liste = Vide | Cons arbre*arbre_liste
```

Remarque 4.7 On passe souvent cela sous le tapis grâce au polymorphisme qui définit des manières de construire des types et non des types directement

**Commentaire 4.5** Dans la défense de plan, on peut parler ici des différentes définition des arbres (par coinduction, avec une infinité de constructeur (pour chaque  $k \in \mathbb{N}^*$  d'arité k, pour les arbres à k fils), par un constructeur  $Ajout_-fils$  d'arité k où le premier argument est l'arbre sans son premier fils, et le dernier argument le premier fils (on en déduit les cas de bases))

#### 3 Ensembles inductifs

#### I Formules propositionnelles

**Définition 4.7 (formule propositionelle)** Soit *V* un ensemble de variables et la signature

- $-\mathcal{B} = \{\top, \bot\} \cup V$
- le constructeur ¬ d'arité 1
- les constructeurs  $\vee$ ,  $\wedge$  et  $\rightarrow$  d'arité 2 (en forme infixe)

Les formules propositionnelles forment l'ensemble inductif défini par cette signature

Exercice 4.5 Défini inductivement le nombre de variables présent dans la formule

**Définition 4.8** On appelle valuation (ou distribution de vérité) toute fonction  $v: V \to \{0, 1\}$ 

**Définition 4.9 (Evaluation d'une formule)** Soit v une valuation. La fonction d'évaluation d'une formule  $[.]_v : F \to \{0,1\}$  se définit inductivement par

- $\bullet$   $[\top]_v = 1$
- $[\bot]_v = 0$
- $[x]_v = v(x)$  pour  $x \in V$

- $[\neg F]_v = 1 [F]_v$
- $[f_1 \wedge f_2]_v = \min([f_1]_v, [f_2]_v)$
- $[f_1 \vee f_2]_v = \max([f_1]_v, [f_2]_v)$
- ullet  $[f_1 o f_2]_v=\left\{egin{array}{ll} 0 & \emph{si}\ [f_1]_v=0 \ \emph{et}\ [f_2]_v=1 \ 1 & \emph{sinon} \end{array}
  ight.$

Exercice 4.6 Définir l'équivalence entre formules et montrer par induction structurelle que, à équivalence près, on peut ne garder que les constructeurs  $\neg$  et  $\lor$ 

#### **II** Langages

Commentaire 4.6 lci comme exemple on aurait aussi pu prendre les langages réguliers, cela est plus pertinent comme construction, mais nécessite d'avoir déjà les définitions de bases sur les langages. Et de plus trouver des inductions parait non trivial

**Définition 4.10** Soit  $\Sigma$  un ensemble (appelé alphabet) fini et non vides d'éléments (appelés lettres). On définit inductivement l'ensemble des mots sur  $\Sigma$ ,  $\Sigma^*$  par la signature :

- $\varepsilon$  (le mot vide) comme cas de base
- Si  $a \in \Sigma$  et  $w \in \Sigma^*$ ,  $wa \in \Sigma^*$

Remarque 4.8 On aurait aussi pu prendre comme définition de  $\Sigma^*$ ,  $\bigcup_{n\geq 0} \Sigma^n$ 

**Définition 4.11** La concaténation de deux mots  $w_1, w_2 \in \Sigma^*$  se définit inductivement comme :

- $concat(w_1, \varepsilon) = w_1$
- $concat(w_1, w_2.a) = concat(w_1, w_2).a$

**Exercice 4.7** Montrer par induction structurelle que  $concat(w_1, concat(a, w_2)) = concat(w_1.a, w_2)$ 

## Implémentations et applications des piles, files et files de priorité

Auteur e s: Emile Martinez

Références :

**Commentaire 5.1** Comme il y a beaucoup à dire, et que le titre ne mentionne pas d'aspects théoriques sur les structures, on suppose ici les structures déjà définie dans le cours. Ainsi, on rappelera uniquement, pour uniformisation les méthodes caractéristiques. On se concentre ainsi sur les implémentations et les applications.

#### 1 Les piles

Rappel: Une pile est une structure de données avec les méthodes vide, est\_vide, empiler, depiler.

#### I Implémentation par listes

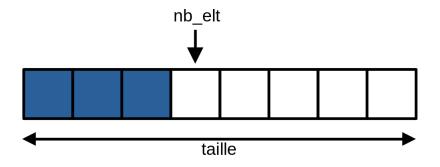
Cette manière est immédiate et donc naturelle.

Exercice 5.1 (Au tableau avec participation des élèves) A quoi correspondent les opérations de bases de la pile sur une liste (à l'oral et éventuellement avec le dessin d'une liste simplement chaînés pour montrer les modifications).

Les listes étant naturelles en OCaml, nous les implémenterons de cette manière en Ocaml. Néanmoins cette pile est immuable.

#### II Implémentation par tableaux

La deuxième manière est en utilisant un tableau.



**Idée 5.1** Pour cela, on utilise un indice nb\_elt qui nous indiquera à quelle case du tableau correspond le sommet de la pile, les cases précédentes du tableau contenant les autres éléments empilés.

**Implémentation 5.1** On doit soit alors utiliser un tableau de taille fixe (et donc connaître à l'avance le nombre max d'éléments dans la pile)

Exercice 5.2 Quels sont les inconvénients de cette implémentation? ( le fait qu'il faut soit utilisé un tableau dynamique, soit connaître à l'avance la taille maximale de la pile)

**Implémentation 5.2** en C en TP avec les déclarations déjà faites, vide également, et le corps des autres fonctions à remplir

Remarque 5.1 Les problèmes sont exactement similaires à ceux de l'implémentation d'une liste par un tableau. Cela vient de la proximité entre une liste et une pile.

Exercice 5.3 Laquelle de ces deux implémentations est mutable? Immuable?

#### III Complexité

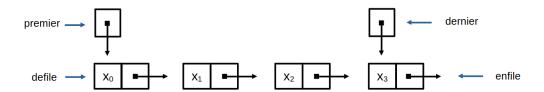
Toutes ces opérations sont en O(1). De plus sa complexité spatiale n'est, si l'implémentation est bien effectuée, que O(hauteur maximale de la pile)

#### 2 Les files

Rappel : Une file est une structure de données avec les méthodes vide, est\_vide, enfiler, defiler.

#### I Par une liste chaînée

Idée 5.2 On stocke les entrées dans une liste et on à l'aide de pointeurs le début et la fin de la file.



**Implémentation 5.3** Ainsi, ajouter des éléments consiste seulement à enlever l'élément du début et à passer début sur l'élément suivant de la liste et enlever un élément consiste simplement à ajouter un élément à la fin de la liste et à y faire pointer le pointeur fin.

Exercice 5.4 Quelle est l'intérêt des pointeurs fin et début ?(fin pour trouver la fin de la liste en O(1), début pour repérer la liste, équivalent à garder le premier élément de la file)

Exercice 5.5 Comment encode-t-on la file vide?

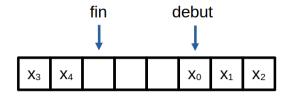
#### II Par un tableau

**Idée 5.3** Les éléments sont stockés consécutivement dans un tableau avec deux indices début et fin indiquant dans le tableau le début de la liste et la fin de la liste.

Exercice 5.6 Quelle est la complexité de chaque opération élémentaire?

**Problème :** La complexité spatiale est en O(nombre de enfile) alors que l'on souhaiterait avoir O(longueur maximale de la file)

**Idée 5.4** Pour cela, si l'on connaît à l'avance une borne sur cette longueur maximale, on peut utiliser des indices modulo cette borne (et ainsi utilisé un tableau «circulaire»)



Ces deux implémentations sont mutables.

#### III Par deux listes mais de manière immuable

Idée 5.5 Il est possible de créer efficacement une telle structure en utilisant uniquement deux piles :

- La première contiendra les éléments prêts à sortir
- La deuxième contiendra les éléments que l'on vient de rajouter

Remarque 5.2 En choississant efficacement quand on les fait passer de l'un à l'autre, on peut avoir une structure efficace.

**Proposition 5.1** Il existe une implémentation de la structure de file pour laquelle la complxité temporelle de chaque opération est en O(1) amorti

**Développement** Implémentation d'une file PAPS avec deux listes et (au choix) introduction à la complexité amortie / implémentation par une liste doublement chaînées

#### IV Pour aller plus loin

Une liste doublement chaînée peut, au pris d'une lourdeur relative dans l'implémentation, fournir immédiatement les opérations de la pile et de la file combinée en O(1)

#### 3 File de priorité

Rappel : Une file de priorité est une structure de donnée ayant les méthodes vide, est\_vide, insérer, extraire\_min

#### I En théorie

Idée 5.6 Nous implémenterons les files de priorité à l'aide de tas min.

**Définition 5.1** Un tas min est un arbre binaire presque complet où chaque noeud à un attribut plus petit que ceux de ses fils

**L'insertion** On ajoute l'élément à l'endroit au seul endroit qui préserve la structure de tas (petit dessin). Ensuite, on l'inverse successivement avec son père, si il est plus petit que lui.

Théorème 5.1 cet algorithme préserve la structure de tas min

**Récupérer l'élément minimum** On enlève la racine, on prend le dernier élément du tas, on le met à la position de la racine, et tant qu'un fils est plus petit que lui, on l'échange avec son fils le plus petit.

Théorème 5.2 Cet algorithme préserve la structure de tas.

**Théorème 5.3** Toutes ces opérations sont en  $O(\log(n))$  où  $\log(n)$  est le nombre d'éléments dans le tas.

Commentaire 5.2 Cette application n'est pas avec les autres car assez immédiate

**Application 5.1** *Tri par tas en*  $O(n \log(n))$ 

#### II En pratique

**Idée 5.7** Pour implémenter de tels arbres, on peut les implémenter comme des structures récursives, en gardant le chemin jusqu'à la dernière feuille sous forme de listes de droite/gauche

Exercice 5.7 Expliciter l'algorithme permettant de mettre à jour le chemin

**Commentaire 5.3** C'est un algorithme d'addition binaire, où quand on doit rajouter un 1 (droite), on rajoute un 0 (gauche). Donc c'est cet algorithme avec 111+1=0000 et 0000-1=111 (et le nombre de 0 qui importe)

Exercice 5.8 Implémenter cette structure en OcamL

**Idée 5.8** Sinon, on peut l'implémenter comme un tableau où le fils de l'élément à l'indice i, sont stockés aux indices 2i + 1 et 2i + 2.

Exercice 5.9 Faire cette implémentation en C

### 4 Applications aux graphes

#### **Algorithme 5.1**: Parcours de graphe

```
\begin{array}{c} a\_faire \leftarrow vide() \\ a\_faire.ajouter(s0) \\ \textbf{tant que} \ \underline{a\_faire} \ \text{n'est pas vide} \ \textbf{faire} \\ u \leftarrow a\_faire.extraire() \\ \textbf{si} \ \underline{u} \ \text{n'a pas encore \'etait visit\'e} \ \textbf{alors} \\ \boxed{\begin{array}{c} \textbf{pour} \ \underline{v} \ \text{voisin de} \ \underline{u} \ \textbf{faire} \\ \underline{u} \ a\_faire.ajouter(v) \end{array}} \end{array}}
```

Si  $a\_faire$  est une pile, on fait un parcours en profondeur et si  $a\_faire$  est une file PAPS, on fait un parcours en largeur.

#### Algorithme 5.1 (Algorithme de Djikstra)

On cherche la distance dans un graphe pondéré d'un sommet s à chaque autre sommet.

On fait le parcours de graphe avec une file de priorité pour  $a_-faire$ . On garde un tableau des distances, que l'on met à jour à chaque étape. La priorité dans la file est la distance que l'on a au moment de l'insertion, et on ajoute toujours les voisins non encore visité.

On obtient alors les plus courts chemins.

#### 5 Applications systèmes

Ces structures sont utilisés dans de nombreuses applications à bas niveau.

#### I Pile d'appel

Quand on exécute un programme avec des appels successifs à des fonctions, de nouvelles variables sont crées, des emplacements pour les arguments, etc..., mais à la fin de la fonction, on doit restaurer l'environnement précédent.

**Idée 5.9** Pour cela, à chaque appel de fonctions, on empile l'état actuel sur une pile, et à chaque retour de fonction, on restaure l'état au sommet de la pile (que l'on dépile).

Commentaire 5.4 Suivant la place (notamment si on ne prend pas tous les exemples), on peut rajouter un schéma

#### II Ordonnancement

Pour gérer le parrallélisme, un ordonnanceur doit décider, quel processus doit être executé. Pour cela on peut par exemple :

- stocker les processus dans une file de priorité pour que les processus les plus importants soient executés en premier.
  - **Exemple 5.1** avec comme clé, la date butoire de fin d'éxecution, on exécute en premier les plus urgents
- Mettre les processus dans une file, en prendre le premier élément, l'exécuté pendant un certain temps, puis le remettre en queue de file. C'est l'algorithme du tourniquet, qui garantie que tous les processus s'exécuterons un jour.

#### III Tampon

Dès que l'on a deux programmes dont la sortie de l'un est branché sur l'entrée de l'autre, et qui ne travaille pas à la même vitesse, on doit mettre un tampon entre les deux. On utilise alors une file PAPS pour stocker les données en attendant que le deuxième programme les récupère.

**Exemple 5.2** On reçoit des paquets du réseau. On doit les récupérer. On les mets dans un tampon, le temps que le programme viennent les traiter. On les restiture alors dans l'ordre d'arrivée grâce à la file.

Commentaire 5.5 Par manque de place, on peut éventuellement passer sur certains exemples, et eventuellement rajouter plein de schéma un peu partout dans la leçon. De plus, on peut évoquer à l'oral la vraie application dans un cours, surtout pour les piles et les files, qui seraient l'application pédagogique d'illustrer la différence type abstrait et structure sous-jacente, et donc ce que sont les méthodes sur les structures et la modularité de tout cela.

## Implémentations et applications des ensembles et des dictionnaires

Auteur e s: Emile Martinez

Références :

#### 1 Dictionnaire : type abstraits et motivation

Définition 6.1 (Dictionnaire) Soit X un ensemble d'éléments appelés valeurs, et K un ensemble d'éléments appelés clés. Un dictionnaire D est une structure de données abstraites ayant les trois opérations :

- Inserer(D, k, x) : insère le couple (k, x) dans D, en écrasant un éventuel couple (k, x') préexistant.
- Recherche(D,k): renvoie la valeur de x telle que (k,x) est dans D, si elle existe (peut renvoyer une valeur pas dans X sinon)
  - Supprime(D, k) supprime un éventuel couple (k, x) présent dans D.

**Exemple 6.1** annuaire téléphonique : les clefs sont les noms des personnes, les valeurs leurs numéros de téléphone

Remarque 6.1 Les dictionnaires sont aussi appelés tableaux associatifs

**Application 6.1** Si on a une base de données de personnes, identifiés par un pseudonyme, on peut stocker leur informations dans un dictionnaire.

Remarque 6.2 C'est ce qui se passe dans une base de données

Implémentation 6.1 (naive) On pourrait stocker tous les éléments dans une liste, sans ordre particulier

Exercice 6.1 Implémenter alors les fonctions de bases. Quelles sont leur complexité?

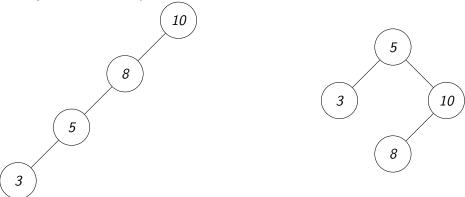
#### 2 Implémentation

- I Par des arbres
- A Arbres binaires de recherche (ABR)

**Définition 6.2 (ABR)** Un arbre binaire de recherche (ABR) est un arbre binaire dont les éléments sont munis d'un ordre total et où, pour chaque sous-arbre N(g,x,d), l'élément x est supérieur à tous les éléments de g et inférieur à tous les éléments de d.

**Implémentation 6.2** On peut implémenter un dictionnaire à l'aide d'un ABR à condition que l'ensemble des clefs soit muni d'un ordre total (On insère les couples (clé, valeur) et l'ordre est sur les valeurs)

**Exemple 6.2** Deux implémentations du même ABR :



**Insertion** Dans un ABR, on insère un élément x en descendant depuis la racine, en prenant le fils gauche ou le fils droit selon si x est plus petit ou plus grand que la racine courante, et en créant un nouveau nœud étiqueté par x lorsque l'on ne peut plus avancer.

Recherche Elle se fait de manière analogue

**Suppression** Lorsque le nœud est une feuille ou si le nœud n'a qu'un enfant, alors la transformation est simple. Par contre, si le nœud possède deux enfants, alors il faut retirer le minimum du sous-arbre droit (ou le maximum du sous-arbre gauche) pour le remplacer.

Exercice 6.2 Implémentation des ABR en OCamL

**Proposition 6.1** Soit A un ABR à n nœuds et de hauteur h. La recherche, l'insertion et la suppression se font dans le pire cas en O(h) comparaisons. Or un ABR peut être déséquilibré : la hauteur est alors en O(n)

#### B Arbres rouge-noir (ARN)

**Définition 6.3** Un arbre rouge noir (ARN) est un ABR où chaque nœud porte une couleur rouge ou noir, et qui vérifie les deux propriétés suivantes :

- la racine est noire
- les potentiels fils d'un nœud rouge sont noirs
- pour chaque nœud, tous les chemins menant de ce nœud à une feuille ont le même nombre de nœuds noirs.

**Proposition 6.2** Les ARN sont équilibrés  $(h = O(\log n))$ 

**Corollaire 6.1** Dans un ARN, on peut effectuer les opérations d'insertion, de recherche et de suppression en O(h), ie  $O(\log n)$ .

Developpement Preuve de la propriété 6.2 et présentation de l'insertion dans un ARN

#### II Tables de hachage

**Idée 6.1** Le but ici va être de stocker nos données dans un tableau (d'où le nom tableau associatif). Cela se fait donc en deux étapes :

- Associer à notre données un nombre (pas trop grand) (appelé hachage) par une fonction appelée fonction de hachage.
- Avoir un tableau avec une case par hachage possible, où l'on stocke la donnée

#### A Fonction de hachage

**Définition 6.4** Une fonction de hachage est une fonction  $h: K \to [0, m-1]$  (avec m << |K|)

**Proposition 6.3** Une fonction de hachage a la propriété du hachage parfait si pour  $x \neq y \in K$ ,  $\mathbb{P}(h(x) = h(y)) = \frac{1}{m}$ 

Remarque 6.3 Le hachage parfait veut dire que les valeurs de hachage sont comme pris au hasard dans [0, m-1]. Néanmoins, comme on veut que h(x) vaille toujours la même chose, on ne prend pas de fonctions aléatoires.

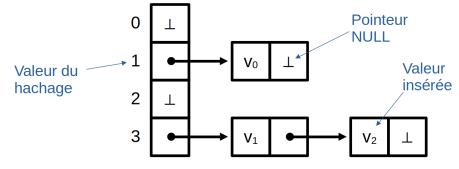
**Exemple 6.3** On choisit un flottant A. On interprète les bits de données de la structure comme un entier x (en les collant). On prend alors  $h(d) = |A * x| \mod m$ 

#### B Table de hachage

Il y a trois étapes dans le stockage dans un tableau :

- 1. Hacher la valeur et la mettre dans à sa case dans le tableau
- 2. Si la case était déjà occupée (collision), stocker la donnée dans une structure annexe
- 3. Si le tableau est trop plein, augmenter m (et donc recopier toutes les données).

Exemple 6.4 Schéma où la structure annexe est une liste chaînée pour chaque case



**Commentaire 6.1** Si on a la place on peut ecrire la remarque, sinon le dire à l'oral que si les abr nécessite un ordre total, la table de hachage nécessite de sérialiser ou de donner directement le hachage

**Commentaire 6.2** Normalement là on pourrait parler de compexité, mais on considère que le tableau 3 suffit.

#### 3 Ensembles

**Définition 6.5** Un ensemble est un dictionnaire dans lequel il n'y a pas de clefs. La fonction recherche renvoie donc un booléen qui indique la présence ou non de l'élément.

Remarque 6.4 On déduit alors de l'implémentation des dictionnaires, l'implémentation des ensembles

**Commentaire 6.3** Cette remarque justifie que l'on parle si brièvement des ensembles, et si tard dans la leçon. Beaucoup des choses sur les ensembles se déduisant de celles des dictionnaires

**Idée 6.2** Comme ce sont des ensembles on pourrait également vouloir des opérations ensemblistes comme l'union, l'intersection, etc...

**Implémentation 6.3** On peut faire ces opérations sur les structures précédentes en les parcourant (pour l'union, on insère tous les éléments de l'un dans l'autre par exemple)

Remarque 6.5 Ces opérations réhabilite l'idée de la liste triée

#### Récapitulatif des complexités :

Structure	Insertion	Suppression	Recherche	union	intersection
liste	O(n)	O(n)	O(n)	$O(n \times m)$	$O(n \times m)$
liste triée	O(n)	O(n)	$\log n$	O(n+m)	O(n+m)
ARN	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(n+m)\log(n+m)$	$O(\min(n, m) \log(\max(n, m)))$
Table de	O(n)	O(n)	O(n)	$O(n \times m)$	$O(n \times m)$
hachage	O(1) moy.	O(1) moy.	O(1) moy.	O(n+m) moy.	$O(\min(n,m))$ moy.

Exercice 6.3 Choisir des implémentations en C et les comparer. Si l'on traite les listes triées, ouverture sur les skip listes

### 4 Application

#### I Dictionnaire d'adjacence

Soit 
$$G = (S, A)$$
 un graphe. (où  $S = [1, n]$ )

On peut représenter G par un tableau de dictionnaire D tq D[u] est un dictionnaire contenant les voisins de u

**intérêts**: On a les avantages de la matrice d'adjacence (on detecte rapidement si il y a une arête) et des listes d'adjacence (stockage en —A— et obtention de tous les voisins linéairement).

**Exemple 6.5** Sur un graphe de personnes se connaissant, on sait si A connait B rapidement, mais on n'a pas à stocker tous les false des couples de personnes en se connaissant pas.

#### II Mémoïsation

Supposons que l'on ait une fonction du type

```
fonction (f_args):
corps de f
return x
```

Il se peut que l'on ait beaucoup d'appels à f sur les mêmes arguments, comme des fonctions récurisves en programmation dynamique. En s'inspirant de cette dernière, on peut alors ne faire qu'une fois les appels sur chaque argument grâce à un dictionnaire :

```
fonction f(args):
    Si args est dans dictionnaire:
        renvoyer dictionnaire[args]
    Sinon:
        corps de f
    dictionnaire[args] = x
    renvoyer x
```

#### III Autres applications

Commentaire 6.4 On peut dire à l'oral que en gros, utiliser un dictionnaire est un peu équivalent à  $f:K \to [\![1,K]\!]$ . (c'est plus que simplement le fait logique que, par un tableau classique, c'est équivalent)

Les dictionnaires et les ensembles servent dès que l'on veut accéder rapidement à un élément dont la structure n'est pas un entier.

**Exemple 6.6** En algorithmique du texte, pour associer des valeurs à des chaînes de caractère (Huffman, Boyer-Moore)

**Exemple 6.7** Quand on fait un parcours de graphe dont les sommets ne sont pas [1, n] on peut utiliser un ensemble pour savoir quels éléments on a déjà parcouru.

**Commentaire 6.5** On peut soit insister à l'oral sur cet exemple, soit en faire une sous partie, du fait que c'est une application pour les ensembles

Mais on peut les retrouver également dans beaucoup de domaines comme en bases de données, et dès que l'on manipule un nombre faible de valeur comparés à l'ensemble des valeurs possibles.

**Développement :** Amélioration du tri par comptage par l'usage de dictionnaires.

## Accessibilité et chemins dans un graphe. Applications

Auteur e s: Emile Martinez

Références :

#### 1 Definition

Commentaire 7.1 Les applications sont éparpillées tout le long de la leçon, et relativement peu développer, donc il peut-être rentable des les souligner pendant la défense de plan.

**Définition 7.1 (chemin)** Dans un graphe orienté G (resp. non orienté) on appelle chemin de longueur  $\lambda$  une suite de  $(\lambda + 1)$  sommets  $(s_0, s_1, \ldots, s_{\lambda})$ 

Remarque 7.1 Par convention, on dit qu'il y a un chemin de longueur 0 de tout sommet vers lui-même.

Remarque 7.2 Dans un graphe non-orienté, les chemins sont aussi appelés chaînes.

**Application 7.1** Dans un graphe de flot de contrôle, le critère tous les chemins consiste à trouver des tests qui font tous les chemins possibles du graphe

Commentaire 7.2 Une première application, dont on ne parle pas beaucoup plus parce que ca a pas grand chose a voir. Donc les chemins servent là, mais la théorie derrière n'est pas intéressante par la théorie des graphes. Illustre simplement la diversité de l'utilisation des graphes.

Commentaire 7.3 On peut mentionner que ca fait déjà une première application

**Définition 7.2 (chemin élémentaire)** Un chemin est dit élémentaire s'il ne contient pas plusieurs fois le même sommet.

Commentaire 7.4 Par manque de place, cette définition peut être enlevé

Définition 7.3 (circuit/cycle) Dans un graphe orienté (resp. non orienté), un chemin  $(s_0, \ldots, s_{\lambda})$  dont les  $\lambda$  arcs (resp. arêtes) sont distincts deux à deux et tels que  $s_0 = s_{\lambda}$ , est un circuit (resp. un cycle).

**Exemple 7.1** On dit qu'un circuit est hamiltonien si il passe par tous les sommets une et une seule fois. Décider de l'existence d'un tel circuit dans un graphe est NP-complet (i.e. dur)

Exercice 7.1 On dit qu'un graphe non orienté est Eulérien s'il existe un cycle passant par chaque arête exactement une fois. Montrer qu'un graphe est eulérien si et seulement si tous ses sommets sont de degré pair.

Commentaire 7.5 Ces deux choses là peuvent être présenter comme des formes d'applications, du moins d'application des définitions (il semble important que la NP-complétude de quelque chose soit mentionné dans cette leçon)

Définition 7.4 (accessibilité) Étant donné un graphe G (orienté ou non) et deux sommets s et t, on dit que t est accessible depuis s s'il existe un chemin allant de s à t dans G.

#### 2 Accessibilité

#### I Tri topologique

**Définition 7.5 (tri topologique)** Étant donné un graphe orienté G = (S, A), on dit que  $\sigma : S \to [\![1, |S|]\!]$  est un tri topologique si  $(s,t) \in A \implies \sigma(s) < \sigma(t)$ 

Corollaire 7.1 Soit  $\sigma$  un tri topologique sur G. Pour  $s,t\in S$ , si il existe un chemin de s à t, alors  $\sigma(s)\leq \sigma(t)$ 

**Proposition 7.1** G est acyclique si et seulement si G admet un tri topologique.

Démonstration pour le sens direct. On montre par l'absurde par récurrence qu'un graphe acyclique a un sommet source.

On montre par récurrence la proposition sur  $\left|S\right|$ 

#### **Algorithme 7.1** Construction d'un tri topologique

• Créer une pile vide

- Faire un parcours en largeur postfixe de G en appliquant la fonction empile
- Renvoyer la pile

#### **Application 7.2** Ordonnancement de tâches

**Définition 7.6** Soit  $T = \{t_1, \ldots, t_n\}$  un ensemble de tâches d'un ordinateur et  $C = T^2$  un ensemble de contraintes  $((t_i, t_j) \in C$  veut dire que  $t_i$  doit être fait avant  $t_j$ ). Un ordonnancement de ces tâches est un ordre d'éxécution de ces tâches.

Proposition 7.2 On peut trouver un ordonnancement en temps linéaire

Démonstration. On prend le graphe (T,C) est on fait un tri topologique.

#### II Connexité

**Proposition 7.3** La relation «il existe un chemin de s à t et de t à s» est une relation d'équivalence.

Exercice 7.2 Montrer que le graphe quotienté par cette relation d'équivalence est acyclique

Commentaire 7.6 lci on introduit le DAG des classes des composantes (fortement) connexes. On peut néanmoins dire que suivant le niveau de la classe, il est très probable que le terme quotienté ne soit pas maitrisé. Donc la on le met par concision, au cas où il aurait déjà était vu en maths (hors programme en maths), mais en vrai on pourrait périphraser et faire des définitions. De plus la c'est un plan, donc on dit ce qu'on ferait dans l'exercice, pas tout l'énoncé rigoureux.

**Définition 7.7** Dans un graphe non orienté (resp. orienté), les classes d'équivalence de cette relation sont appelés composantes connexes (resp. fortement connexes).

Si il n'y a qu'une seul classe, le graphe est dit connexe (resp. fortement connexe)

Commentaire 7.7 On prend ca comme déf et non pas la propriété suivantes en ayant défini connexe comme un chemin de tous le monde à tout le monde, pour avoir une définition plus explicites et naturelles que de passer par la maximalité. Néanmoins, cela nécessite l'abstraction de la classe d'équivalence (vue en maths). Si la classe est faible, on peut faire tout ca plus avec les mains.

Exercice 7.3 Dans un graphe connexe, deux chemins élémentaires maximaux ont un nœud en commun.

**Proposition 7.4** Une composante connexe (resp. fortement connexe) est un sous-graphe connexe (resp. fortement connexe) maximal.

#### Algorithme 7.2

#### **Algorithme 7.1 :** Calcul des composantes connexes (cas non orienté)

#### tant que un sommet n'est pas visité faire

Créer une nouvelle composante connexe

Parcourir le graphe des sommets non visités depuis un sommet v non visité en ajoutant a la composante tous les sommets que l'on croise

Pour les composantes fortement connexes, il faudra plus qu'un simple parcours.

#### Algorithme 7.3

#### Algorithme 7.2 : Algorithme de Kosaraju

Appliquer l'algorithme de construction d'un tri topologique (meme si le graphe a des cycles) Prendre  $G^T$  le graphe transposé de G (i.e., (u,v) devient (v,u)) pour <u>i</u> allant de 1 à n faire

Si  $\sigma(i)$  n'a pas déjà été visité

Créer une nouvelle composante fortement connexe

Visiter  $G^T$  depuis  $\sigma(i)$  en ajoutant les sommets visités non encore attribués

Proposition 7.5 Cet algorithme construit les composantes fortement connexes en temps linéaire

**Définition 7.8** Le problème 2-SAT est le problème de savoir si étant donné n variables  $x_1, \ldots, x_n$  et p clauses  $C_1, \ldots, C_p$  de taille 2 sur  $x_1, \ldots, x_n$ ,  $\varphi = \bigwedge_{i=1}^p C_i$  est satisfiable

**Developpement :** Résolution en temps linéaire de 2-SAT.

#### 3 Plus court chemin

**Définition 7.9 (graphe pondéré)** Un graphe pondéré est un graphe G = (S, A) muni d'une fonction de poids  $w : A \to Z$ .

Le poids d'un chemin est alors défini comme la somme des poids des arêtes qui le compose.

Remarque 7.3 On peut étendre  $w \ \text{à} \ S^2$  en posant  $w(u,v) = +\infty$  lorsque  $(u,v) \notin A$ .

**Définition 7.10** Dans un graphe G, un plus court chemin (pcc) de u à v ( $u, v \in S$ ) est un chemin de poids minimal de u à v

Remarque 7.4 Si les poids sont unitaires, on peut trouver le pcc entre deux sommets u et v en faisant un parcours en largeur depuis u.

Commentaire 7.8 On considère les parcours déjà vu (servant dans bien d'autres contextes que les chemins dans les graphes). Ici on fait simplement le lien, et on illustre la notion. On pourrait également le faire sur un exemple au tableau, et essayer de le faire devnier aux élèves (lien entre différentes parties du cours)

#### I D'un sommet à tous les autres

Lorsque la fonction de poids est à valeur dans N, on peut utiliser l'algorithme de Dijkstra.

## Algorithme 7.3 : dijkstra(G, S)

```
\begin{array}{l} \textit{distance} \leftarrow \mathsf{tableau} \; \mathsf{de} \; \mathsf{taille} \; |S| \; \mathsf{initialis\acute{e}} \; \mathsf{a} \; + \infty \\ \\ \textit{distance}[s] \leftarrow 0 \\ F \leftarrow FilePriorite() \\ \textit{Inserer}(F, s, 0) \\ \\ \mathsf{tant} \; \mathsf{que} \; \underbrace{\neg estVide(F) \; \mathsf{faire}}_{\substack{u, \, du \leftarrow ExtraireMin(F)}} \\ \quad \mathsf{u}, du \leftarrow ExtraireMin(F) \\ \\ \mathsf{pour} \; \underbrace{v \in N(u) \; \mathsf{faire}}_{\substack{d \leftarrow du + w(u, v) \\ \mathsf{si} \; \underline{d} < distance[v] \; \mathsf{alors}}_{\substack{| \; \mathsf{Si} \; distance[v] = +\infty \\ | \; \mathsf{Inserer}(F, v, d)}} \\ \quad \mathsf{sinon} \\ \quad DiminuerPriorite(F, v, d) \\ \quad \mathsf{distance}[v] \leftarrow d \\ \\ \\ \mathsf{retourner} \; distance \end{array}
```

#### Algorithme 7.4

Proposition 7.6 L'algorithme de Dijkstra réalise au plus |S| appels à Inserer et ExtraireMin, et |A| appels à DiminuerPriorite. Donc avec un tas min, on obtient  $O(|A| \times \log |S|)$ 

Remarque 7.5 Si la structure d'entrée est une matrice d'adjacence, on peut faire l'algorithme en  $O(n^2)$  sans structure particulière pour F.

**Remarque 7.6** Lorsque la fonction de poids est à valeur dans  $\mathbb{Z}$  et que le graphe ne contient aucun circuit absorbant, on peut utiliser l'algorithme de Bellman-Ford.

#### Application 7.3 Détection des cycles absorbants.

**Remarque 7.7** Si l'on souhaite seulement le plus court chemin entre deux points, on peut utiliser l'algorithme  $A^*$  (Dijkstra + heuristique du chemin restant).

#### II De tous les sommets à tous les sommets

Lorsque le graphe ne contient aucun cycle absorbant, l'algorithme de Floyd Warshall calcule les plus courts chemins entre toute paire de sommets de  $S = \{1, \ldots, n\}$  par programmation dynamique.

- $\star$  Sous-problèmes :  $d^{(k)(i,j)}$  la distance du pcc de i à j avec seulement  $[\![1,k]\!]$  comme sommets intermédiaires
- \* Relation de récurrence

$$\begin{split} &d^{(0)}(i,j) = w(i,j) \\ &d^{(k+1)}(i,j) = \min \left( d^{(k)}(i,j), \ d^{(k)}(i,k) + d^{(k)}(k,j) \right) \end{split}$$

 $\star$  **Résolution :** On résout sur  $S^2$  à k croissant

**Proposition 7.7** Floyd Warshall est en  $O(n^3)$ 

Remarque 7.8 Si les poids sont positifs, appliquer dijkstra à chaque sommet nous donne  $O(n \times |A| \times \log n)$ 

Remarque 7.9 Cette algorithme utilise une matrice d'adjacence (algorithme centralisé)

**Algorithme 7.5** Si on a des listes d'adjacence (algorithme décentralisé/distribué), on peut utiliser l'algorithme de Bellman Ford

**Application 7.4** Routage des paquets d'un réseau par le protocole IP avec l'algorithme de Bellman Ford.

**Developpement :** Presentation et terminaison de l'algorithme de Bellamn Ford.

Commentaire 7.9 On a fait une leçon sur les graphes, sans aucun dessin de graphes. En vrai, il pourrait y en avoir sur des exemples, et puis les schémas ne sont pas absolument necessaires pour illustrer la plupart des concepts, dont surtout la formalisation est imporante (la def d'un chemin est explicite).

# Leçon 8

# Algorithme de tri. Exemple, Complexité et Applications

Auteur e s: Emile Martinez

Références :

#### 1 Introduction

**Définition 8.1** Un algorithme de tri prend en entrée un liste d'éléments E muni d'un ordre total  $\leq$  ( mais dont on peut se passer de l'antisymétrie) et renvoie o=une liste S telle que :

- 1. elle contient exactement les éléments de E
- 2. les éléments de S apparaissent dans l'ordre croissant

Application 8.1 Pourquoi trier? Cela permet de simplifier des opérations (min, max, recherche, etc...)

Exercice 8.1 Chercher à la main un mot dans une liste triée et non triée.

Commentaire 8.1 On peut faire cet exercice en seconde. Avec éventuellement le fait de comparer deux listes de mots. Tout ca pour voir l'intérêt du tri. Ensuite on peut leur demander comment faire pour trier, permettant de faire émerger des algorithmes sans le formalismes nécessaires. Et suivant le format des mots, on obtiendra probablement des choses différentes (une liste écrit sur un papier -¿ tri par sélection, des cartes avec les mots -¿ tri par insertion, tri a bulle, voir même du tri par paquet).

Ainsi on peut faire de l'informatique sans l'écueil de l'apprentissage de la syntaxe python qui bloque beaucoup d'élèves.

**Définition 8.2 (Propriétés des tris)** • en place : Utilise O(1) espace en plus de l'espace des données d'entrées

- stable : Si  $E[i] \le E[j]$  et si  $E[j] \le E[i]$ , avec i < j, dans S, E[i] apparaîtra avant E[j]
- en ligne : on peut trier les données même si elles arrivent au fur et à mesure
- parallélisable : on peut diviser le travail sur plusieurs fils.

## 2 Tri quadratiques

#### I Tri par sélection

<b>Exemple 8.1</b> $E = [4, 3, 6, 1]$						
i	E	m	S			
×	[4, 3, 6, 1]	×	[]			
0	[4, 3, 6]	1	[1]			
1	[4, 6]	3	[1, 3]			
2	[6]	4	[1, 3, 4]			
3	[]	6	[1, 3, 4, 6]			
S = [1, 3, 4, 6]						

**Commentaire 8.2** Cet exemple peut être remplacer par simplement : «Exemple : mettre un exemple d'execution de l'algorithme» si on manque de place

#### **Proposition 8.1**

- \* Terminaison : l'algorithme n'utilise que des boucles bornées
- $\star$  Correction : Invariant de boucle «S est trié et contient les i plus petits de E»
- $\star$  Cout : environ  $|E|^2$

**Proposition 8.2** Le tri par sélection est stable (si on extrait le premier min) mais ni en ligne, ni en place, ni facilement parallélisable

Exercice 8.2 Réécrire le tri pour qu'il soit en place. Qu'advient-il de la stabilité?

#### II Tri par insertion

#### **Algorithme 8.2 :** $Tri\_par\_insertion$

Proposition 8.3 L'algorithme 8.2 est stable, en place et en ligne.

Remarque 8.1 Il est difficilement parallélisable

Exercice 8.3 Quel est la complexité de cet algorithme

#### III Recherche Dichotomique

#### Algorithme 8.3 : $Recherche\_dichotomique(E, x)$

```
\begin{array}{c|c} \mathbf{si} & |E| = 0 \text{ alors} \\ & \mathbf{retourner} & \underline{\mathsf{Faux}} \\ \mathbf{sinon} \\ \hline\\ & a \leftarrow 0, \ b \leftarrow |E| - 1, \ m \leftarrow \left\lfloor \frac{a+b}{2} \right\rfloor \\ & \mathbf{tant} & \mathbf{que} & \underline{E[m]} \neq x \text{ et } (b-a) > 0 \text{ faire} \\ & \mathbf{si} & \underline{E[m]} < x \text{ alors} \\ & & |a \leftarrow m+1 \\ & \mathbf{sinon} \\ & & |b \leftarrow m-1 \\ & & |m \leftarrow \left\lfloor \frac{a+b}{2} \right\rfloor \\ \\ \mathbf{si} & \underline{E[m]} = x \text{ alors} \\ & |\mathbf{retourner} & \underline{\mathsf{Vrai}} \\ & \mathbf{sinon} \\ & |\mathbf{retourner} & \underline{\mathsf{Faux}} \\ \hline \end{array}
```

**Terminaison :** variant de boucle :  $\ll b - a \gg$ 

**Correction :** invariant de boucle : «Si x est dans E alors son indice est entre a et b»

**Cout** : nombre de bit de |E|

Implémentation 8.1 Implémentation en Python et comparaison avec la recherche linéaire

Exercice 8.4 Écrire une version récursive de l'algorithme

#### 3 Tri efficace

#### I Tri fusion

Définition 8.3 L'algorithme de tri fusion est un algorithme de tri qui repose sur deux opérations :

- partitionner(L) : coupe L en deux listes de taille équivalente  $L_1$ ,  $L_2$
- $fusion(L_1, L_2)$  : avec  $L_1$  et  $L_2$  deux listes triées, renvoie  $L_3$  la liste triée contenant tous les éléments de  $L_1$  et  $L_2$ .

#### **Algorithme 8.4**: fusion( $L_1$ , $L_2$ )

```
res \leftarrow []
i, j \leftarrow 0
\mathsf{tant} \ \ \mathsf{que} \ \underline{i < |L_1| \ \mathsf{et} \ j < |L_2|} \ \ \mathsf{faire}
| \ \ \underline{si} \ \underline{L_1[i] < L_2[j]} \ \ \mathsf{alors}
| \ \ \underline{res.} \mathsf{ajouter}(L_1[i])
| \ \ i \leftarrow i+1
| \ \ \mathsf{sinon}
| \ \ res. \mathsf{ajouter}(L_2[j])
| \ \ j \leftarrow j+1
```

Ajouter le reste de  $L_1$  et de  $L_2$  à res

retourner res

#### Algorithme 8.5 : $tri_fusion(L)$

**Developpement:** Correction totale du tri fusion

Proposition 8.4 Ce tri est stable mais pas en place. Parallélisable mais pas en ligne.

```
Complexité: C(n) = 2 \times C(\frac{n}{2}) donc C(n) = O(n \times \log n)
```

#### II Tri rapide

**Idée 8.1** Choisir un élément appelé pivot et mettre à gauche tous les éléments plus petit, à droite tous les plus grands, puis à trier cette partie à droite et à gauche.

#### Algorithme 8.6 : $tri\_rapide(L, debut, fin)$

```
\begin{array}{c} \mathbf{si} \ \underline{debut} \geq fin-1 \ \mathbf{alors} \\ \hline \mathbf{retourner} \ \underline{L} \\ pivot \leftarrow L[0] \\ i \leftarrow debut \\ j \leftarrow fin \\ \mathbf{tant} \ \mathbf{que} \ \underline{i < j} \ \mathbf{faire} \\ \hline \mathbf{si} \ \underline{L[i+1] \leq pivot} \ \mathbf{alors} \\ \hline \quad \underline{echanger} \ L[i+1] \ \mathbf{et} \ L[i] \\ \hline \quad i \leftarrow i+1 \\ \hline \mathbf{sinon} \\ \hline \quad \underline{echanger} \ L[i+1] \ \mathbf{et} \ L[j] \\ \hline \quad \underline{j \leftarrow j-1} \\ \hline \quad tri\_rapide(L,debut,i-1) \\ \hline \quad tri\_rapide(L,debut,i+1,fin) \\ \end{array}
```

Commentaire 8.3 Par manque de place, on peut remplacer l'écriture de cet algorithme par un dessin expliquant l'idée, et mettre son écriture en exo

```
Proposition 8.5 (Complexité) — pire des cas : O(n^2) — meilleur cas : O(n \log n) — cas moyen avec pivot aléatoire : O(n \log n) — pire cas avec pivot astucieux : O(n \log n)
```

Proposition 8.6 Ce tri est en place, non stable, non en ligne mais parallélisable

Commentaire 8.4 On peut éventuellement mentionner que dans beaucoup d'implémentation, pour le pivot on prend quelques valeurs (exemple 5) et on prend la médiane de ces valeurs là (ainsi on est quasiment jamais dans le pire cas et sans devoir calculé la médiane). Mais avec l'avantage de rester en place

Commentaire 8.5 Pour le caractère en place, il faut discuter de la pile d'appel. A priori, l'espace supplémentaire utilisé est en  $O(\log n)$  (voir  $O((\log n)^2$  si on considère le stockage des indices mais là on part un peu trop loin)) et non O(1), mais on s'en contente souvent.

Exercice 8.5 Écrire une version stable de ce tri. Préserve-t-on le caractère en place.

#### III Tri par tas

#### Algorithme 8.7 : $tri\_tas(L)$

Insérer les éléments  $\overline{\text{de }L}$  dans un tas initialement vide Extraire successivement l'élément minimum du tas.

Exercice 8.6 Quelles propriétés vérifie ce tri?

#### IV Minoration de la complexité du tri

**Proposition 8.7** On ne peut pas trier n éléments avec une complexité inférieure à n-1

**Proposition 8.8** Un algorithme de tri par comparaison aura une complexité pire cas au mieux  $O(n \log(n))$ 

Démonstration. S'intéresser à l'arbre des chemins que prend l'algorithme en fonction du résultat des comparaisons.

Remarque 8.2 Si on ne trie pas par comparaison, on peut avoir des complexités plus faibles. Par exemple, si E ne contient que des entiers entre 0 et 9, on peut simplement compter le nombre de 0 et de 9 puis reconstruire là dessus le tableau trié.

Développement : Amélioration du tri par comptage avec des dictionnaires

#### 4 Application

#### I Algorithmes gloutons

**Définition 8.4** Un algorithme glouton est un algorithme qui résout un problème d'une entrée E de la forme :

- on trie les éléments de E
- on construit une solution en les parcourant, sans revenir en arrière

**Exemple 8.2** On a n évènements sportifs ayant lieu respectivement entre les dates  $d_i$  et  $f_i$  ( $i \in \mathbb{N}$ ) ayant chacun besoin d'un gymnase. Comment allouer des gymnases à des évènements pour utiliser le moins possible de gymnase?

Algorithme glouton:

- 1. Trié les évènements par  $d_i$  croissant (impliquant souvent de trier)
- 2. Mettre chaque évènement dans le premier gymnase vide (peut en être un nouveau)

**Proposition 8.9** Le glouton de l'exemple 8.2 renvoie une solution optiamle (minimisant le nombre de gymnases)

Exercice 8.7 Écrire un algorithme glouton pour le problème de rendu de monnaie

Définition 8.5 Un arbre couvrant minimal d'un graphe pondéré est un sous graphe connexe acyclique de poids minimal

```
Algorithme 8.8 : kruskal

Entrées : L liste d'arêtes

Sorties : Arbre couvrant de poids minimal

Trier L

res \leftarrow [] pour \underline{a} \in \underline{L} faire

\begin{bmatrix} \mathbf{si} & \{a\} \cup res \text{ n'ajoute pas de cycles} \\ res \leftarrow res \cup \{a\} \end{bmatrix}

retourner \underline{res}
```

Exercice 8.8 Proposer des algorithmes gloutons pour la coloration de graphe. Sont-ils optimaux?

#### Il Implémentation des ensembles

Commentaire 8.6 Cette partie fait un peu écho à l'activité mentionner dans le commentaire 8.1

**Proposition 8.10** On peut implémenter les ensembles par des listes, par des listes triées, par des listes que l'on trie pour l'union et l'intersection. On obtient alors les complexités suivantes :

Structure	Insertion	Suppression	Recherche	union / intersection
liste	O(n)	O(n)	O(n)	$O(n \times m)$
liste triée	O(n)	O(n)	$\log n$	O(n+m)
liste avec tri	O(1)	O(n)	O(n)	$O((n+m)\log(\min(n,m)))$

Exercice 8.9 Proposer une implémentation mélangeant les listes triées et les listes avec tri ayant de meilleur complexité

Commentaire 8.7 On s'attend ici à ce que on aient d'une part les éléments déjà triés, de l'autre les éléments pas encore, et on ne trie que quand on fait l'union ou l'intersection (ou éventuellement la recherche) en triant les éléments pas encore triés, puis en fusionnant (cf tri fusion) les deux listes.

# Leçon 9

# Algorithmique du texte. Exemples et applications.

Auteur e s: Emile Martinez

Références:

Un auteur envoie son manuscrit à un éditeur. Il commence par compresser le texte. A la réception, l'éditeur compare le manuscrit à d'autres ouvrages pour vérifier qu'il n'y a pas plagiat. Il peut ensuite chercher un motif dans le texte.

Commentaire 9.1 Cela justifie l'ordre dans lequel on a mis nos parties. De plus, suivant le niveau du cours, on pourrait inaugurer chaque partie en rappelant quelle partie de ce contexte cela concerne. Mais là le niveau (MPI) est un peu élevé pour s'apesentir sur ce genre de choses

Notation: On prend les conventions de slicing de python

Commentaire 9.2 Il n'y a pas de partie application car souvent les applications sont directes depuis les algorithmes. Ainsi on les dissémine illustrant directement le concept

## 1 Encodage et compression

#### I Encodage par lettre

**Définition 9.1 (Algorithme de compresssion)** Un algorithme de compression sans perte est la donnée d'une fonction  $f: \Sigma^* \to \Sigma^*$  injective (il existe un unique décodage).

#### Algorithme 9.1 (Codage préfixe)

- 1. Prétraitement : On construit un arbre binaire A qu'on appelle arbre de Huffman dont les feuilles sont les lettres  $c \in \Sigma$ .
- 2. Compression : On code chaque lettre c par une suite de 0 et 1 correspondant au chemin (0 : gauche, 1 : droite) de la racine à la feuille contenant c dans A.
- 3. Décompression : On décode une suite de 0 et 1 en parcourant le chemin correspondant dans A.

Algorithme 9.2 (Codage de Huffman) On note  $f_a$  la fréquence du caractère a dans le texte et on note  $f_{\mathcal{A}} = \sum_{a \in \mathcal{A}} f_a$ 

**Commentaire 9.3** Mentionner à l'oral qu'on ferait le lien avec le fait que c'est un algorithme glouton sur les arbres unifiant ceux de fréquences des lettres agrégés minimal.

**Théorème 9.1** L'arbre construit par le codage de Huffman 9.2 minimise la quantité  $S = \sum_c \in \Sigma f_c d_c$  où  $d_c$  est la profondeur du caractère c dans l'arbre.

Idée 9.1 Cela revient à dire que l'algorithme de Huffman est optimal parmi les codages préfixes

**Exercice 9.1** Quelle structure pour  $\mathcal{F}$  dans l'algorithme 9.2? Quelle complexité alors?

#### II Encodage par séquences

Idée 9.2 On va associer un code à une séquence de lettres (ou motifs)

Remarque 9.1 Pour cela, on peut utiliser le codage de Huffman, en prenant comme alphabet les mots apparaissant dans le livre. Mais on peut faire quelque chose de spécifique aux séquences, mais moins spécifiques à un livre (car ici le caractère " " comme délimitateur est arbitraire).

Commentaire 9.4 Si on manque de places, on peut faire cette remarque uniquement à l'oral

**Idée 9.3** L'agorithme LZW détermine un codage dans un dictionnaire d au fur et à mesure de la lecture du texte (algorithme online). On va coder certains motifs (groupement de lettres consécutives) présents dans le texte.

#### Algorithme 9.3 (Compression par LZW)

```
Initialement, les lettres de \Sigma sont codées par un entier (par ex. avec le code ASCII). m \leftarrow "
```

#### tant que il reste du texte s à coder faire

Retirer le plus long préfixe w de s qui soit dans dAjouter le codage de w à la fin de m $w' \leftarrow w$  concaténé avec la prochaine lettre de sAjouter un nouveau codage pour w' dans d

retourner m

Remarque 9.2 Pour la décompression, il n'est pas nécessaire de transmettre le dictionnaire car on peut le reconstruire à la volée.

**Application 9.1** Le format de fichier .zip compresse un dossier en utilisant (entre autre) les algorithmes de Huffman et LZW.

Développement : Présentation de la compression et de la décompression de l'algorithme LZW

### 2 Comparaison

#### I Plus longue sous-suite commune (PLSSC)

**Définition 9.2 (Problème PLSSC)** Soit  $x,y\in \Sigma^*$ . Une plus longue sous-suite commune à x et y, noté PLSSC(x,y) est  $argmin\left\{k\left/\exists i,j:x[i:i+k]=y[j:j+k]\right\}$ 

**Application 9.2** Ce problème correspond au fait de trouver des morceaux d'ADN communs entre deux séquençages.

**Exemple 9.1** Pour x =' patate' et y =' frites' on a 'te'

**Algorithme 9.4 (Brute force)** On essaie toutes les séquences possibles → exponentiel

Algorithme 9.5 (programmation dynamique) On considère les sous-problèmes  $c_{i,j} = |PLSSC(x[:i], y[:j])|$ .

On a alors 
$$c_{i,j}=\left\{ egin{array}{ll} 0 & \textit{si}\ i=0\ \textit{ou}\ j=0 \\ c_{i-1,j-1} & \textit{si}\ x[i-1]=y[j-1] \\ \max(c_{i-1,j},c_{i,j-1}) & \textit{sinon} \end{array} \right.$$

**Proposition 9.1** L'algorithme 9.5 calcule PLSSC(x,y) en  $O(|x| \times |y|)$ 

Remarque 9.3 Pour obtenir la sous suite, on sauvegarde d'où l'on vient pour pouvoir reconstruire la solution

#### II Distance entre deux chaînes

**Définition 9.3 (distance)** Une distance sur un ensemble E est une application  $d: E^2 \to R^+$  tq:

$$\begin{array}{ll} d(x,y) = d(y,x) & \textit{(symétrie)} \\ d(x,y) = 0 \equiv x = y & \textit{(séparation)} \\ d(x,z) <= d(x,y) + d(y,z) & \textit{(inégalité triangulaire)} \end{array}$$

**Définition 9.4 (Distance de Hamming)** La distance de Hamming entre deux chaines de caractères de même taille est le nombre de caractères distincts.

**Application 9.3** Dans un protocole réseau, on peut ajouter des bits de contrôle, ayant une information redondante avec les bits du message. Certains messages sont donc invalides (si les bits de contrôle ne correspondent pas). On prend alors le message valide ayant la plus petite distance de Hamming (et ainsi, on peut espérer retrouver le message corrigé).

**Exemple 9.2** Pour «truc» et «troc» c'est 1.

**Définition 9.5** La distance d'édition (ou de levenshtein) entre deux chaînes de est le nombre minimal de transformation pour passer de l'une à l'autre parmi ( $a \in \Sigma$ ,  $i \in \mathbb{N}$ ) :

- $ins_{a,i}$  : insertion de a à la position i
- $sub_{a,i}$  : substitution de la i-ème lettre par a
- $sup_i$  : suppression de la i-ème lettre.

**Application 9.4** On peut utiliser cette algorithme pour détecter des mutations ponctuelles dans des brins d'ADN, et ainsi essayer de les faire correspondre.

**Application 9.5** Dans les logiciels de traitement de texte, les correcteurs orthographiques cherchent dans un dictionnaire le mot le plus proche de celui mal orthographié pour proposer une correction.

**Proposition 9.2** La distance d'édition  $lev : \Sigma^* \times \Sigma^* \to \mathbb{N}$  est une distance. De plus,

$$lev(u.a,v.b) = \min \left\{ \begin{array}{ll} lev(u,v) + (a \neq b) & \textit{Rien, ou substitution si } a \neq b \\ lev(u,v.b) + 1 & \textit{Suppression de } a \\ lev(u.a,v) + 1 & \textit{Insertion de } b \end{array} \right.$$

**Corollaire 9.1** Il existe un algorithme de programmation dynamique calculant lev(a,b) en  $O(|a| \times |b|)$ 

#### 3 Recherche de motifs

#### I Recherche de motifs dans un texte

Définition 9.6 (Problème de recherche de motif) Pour  $m \in \Sigma^*$ ,  $t \in \Sigma^*$ , m est il un sous mot de t?.

Remarque 9.4 On peut éventuellement rajouter les questions «où ?» et «combien de fois»

**Application 9.6** CTRL + F

**Algorithme 9.6 (Solution naïve)** On essaie toutes les positions possibles pour m dans t. L'algorithme est donc en O(|m|\*|t|)

#### **Proposition 9.3**

- 1. Le problème est équivalent à savoir si  $t \in \Sigma^* m \Sigma^*$  qui est rationnel.
- 2. Déterminer si un mot est dans un langage rationnel est linéaire en la longueur du mot
- 3. On peut résoudre le problème en O(|t|) + f(m) (où f peut être très grand)

**Développement :** Construction de l'automate des motifs

Idée 9.4 On essaye de décaler de plus de 1 quand on se trompe

**Commentaire 9.5** C'est ce qu'on fait avec l'automate des motifs. Mais on peut essayer de le faire directement sans passer par le formalisme des automates

**Algorithme 9.7** Boyer-Moore Amélioration de l'algorithme naif en décalant de plus de 1 à chaque fois qu'on se trompe

```
i \leftarrow 0 \text{ tant que } i < |t| - |m| \text{ faire} | \text{pour } \underline{j} \text{ allant de } |m| - 1 \text{ à } \underline{0} \text{ faire} | \text{si } \underline{t[i+j] \neq m[j]} \text{ alors} | i \leftarrow i + decalage[t[i+j]]  | break
```

où decalage[a] : l'indice en partant de la fin de la dernière occurrence de a dans m (|m| si a non présent)

```
Proposition 9.4 Complexité : 
Pire des cas : O(|t| \times |m|) 
meilleur des cas : O\left(\frac{|t|}{|m|}\right) Précalcul : O(|m|) (mais dans le meilleur cas en O(|\Sigma|))
```

Remarque 9.5 On peut mélanger les deux idées pour obtenir quelque chose qui sera en général sous linéaire, mais au pire linéaire (en |t| mais on augmente le cout du précalcul).

**Idée 9.5** Dans l'algorithme de Rabin Karp, on compare directement t[i:i+-m-] avec m grâce à des fonctions de hachage (donc rapidement). Si les hachages sont égaux, on vérifie caractère à caractère, et sinon on incrémente i.

```
Remarque 9.6 Le hachage h défini parh(t_0,...,t_{|m|-1}) = \sum\limits_{j=1}^{|m|-1} B^{|m|-1-j} \times t_j peut se calculer en O(1) à partir du calcul précédent : h(t_i+1,...t_i+|m|) = B \times (h(t_i,...t_i+|m|-1)-B^{|m|-1}t_i) + t_i + 1
```

#### II Analyse lexicale

**Application 9.7** Lors de la compilation d'un programme C, le compilateur reconnait des léxèmes définis par des langages réguliers.

**Exemple 9.3** if (abs < 5) abs += 52; reconnu en IF LPAR VAR INF INT RPAR VAR PLUSEGAL INT

#### Algorithme 9.8

- On ordonne les règles  $e_i o t_i$  et on construit  $\mathcal{A}_i$  un automate reconnaissant  $\mathcal{L}(ei)$
- On exécute en parallère les  $A_i$  sur le texte.
- Quand tous les automates sont bloqués on prend :
  - le préfixe du texte le plus long qui finit dans un état acceptant d'un automate
  - en prenant l'automate de priorité maximale si plusieurs reconnaissent le même préfixe
- On recommence sur le texte restant.

**Commentaire 9.6** Par manque de place on peut ici résumer plus succintement l'algorithme en disant simplement qu'on reconnait chaque lexème avec un automate, en parrallèle pour trouver le bon.

**Application 9.8** grep suivi d'une regexp en norme POSIX et de noms de fichiers affiche toutes les lignes des fichiers qui contiennent la regexp.

**Application 9.9** En SQL, on peut comparer des attributs de type CHAR avec des expression régulières grâce au mot clef LIKE.

**Exemple 9.4** SELECT prénom FROM clients WHERE nom LIKE "%on%";

# Leçon 10

# Arbres : représentations et applications

Auteur e s: Emile Martinez

Références :

#### 1 Généralités sur les arbres

Un arbre est une structure de données récursives stochant hierarchiquement les données. Dans un arbres, les données sont appelées des noeuds.

**Définition 10.1 (arbre)** Un arbre est un couple (u,l) où u est un noeud (élément) et l une liste (potentiellement vide) d'arbre

- ullet u est appelé la racine de l'arbre (u,l)
- si l est vide, u est appelé une feuille
- les arbres de l, sont appelés sous arbres de (u, l)
- Les racines des arbres de l sont appelées enfant de u (et ont u pour parent)
- la hauteur  $h(u) = h((u, l)) = 1 + \max_{A \in l} h(A)$  (et donc 1 si l est vide)

Remarque 10.1 Il n'existe ici pas d'abre vide.

**Exemple 10.2** L'organisation des fichiers en répertoire peut être représenté sous forme d'arbre.

Remarque 10.2 On peut à chaque noeud associer une étiquette. On parle alors d'arbre étiqueté.

**Théorème 10.1** Identifions les arbres à des graphes non orientés où un sommet (la racine) est choisi, en considérant les liens de parentés comme des arêtes. Les arbres sont alors les graphes connexes acycliques

Démonstration. Exercice

Corollaire 10.1 On représente les arbres comme des graphes (cf exemple 10.1)

**Définition 10.2** Un arbre binaire est définit inductivement par :

- E est un arbre vide
- Si  $A_1$  et  $A_2$  sont des arbres binaires et u une donnée,  $B(u, A_1, A_2)$  est un arbre binaire,  $A_1$  étant le sous-arbre gauche, et  $A_2$  le droit.

**Idée 10.1** Les arbres binaires sont des arbres dont les listes sont de taille 2, mais où l'on rajoute des arbres vides.

**Exemple 10.3** Représentation d'une expression arithmétique :

$$3\times (4+5) \\ \rightarrow N(\times, N(3, E, E), A) \\ \textit{avec } A = N(+, N(4, E, E), N(5, E, E)) \\ \textit{E} \qquad E \qquad E \qquad E \qquad E$$

# 2 Représentation informatique

#### I Représentation comme structure inductive

En représentant un arbre en utilisant sa structure inductive, on obtient :

• Pour les arbres généraux

```
type 'a arbre = N of 'a arb_liste and
type 'a bin arb_liste = V | Cons of (a arb *('a arb_liste));;
```

• Pour les arbres binaires

```
type 'a bin = E \mid B of 'a * 'a bin * 'a bin;;
```

**Développement 1 :** Correspondance entre les arbres binaires et les arbres généraux de taille n et utilisation en  ${\sf C}$ 

#### II Représentation comme un graphe

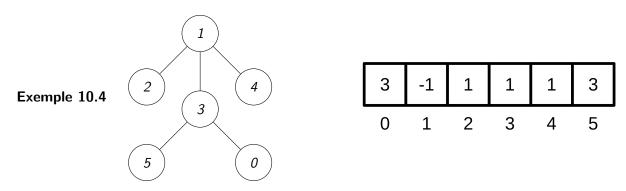
Les arbres étant des graphes connexes acycliques (cf. théorème 10.1), on peut les représentés comme tels :

- par des listes (ou dictionnaires) d'adjacence
- Par une matrice d'adjacence
- Comme la liste de toutes les arêtes

Remarque 10.3 N'exploitant pas la structure d'arbres, ces structures sont peu utilisées.

#### III Représentation par un tableau

SI les identifiants des noeuds sont des entiers de 0 à n-1, on peut stocker l'arbre dans un tableau de taille n, la case i contenant l'identifiant du père du noeud i, -1 si il est racine.



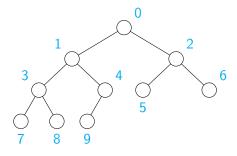
Remarque 10.4 On ne stocke ici que la structure. Pour stocker des données, on produit un tableau de couples.

#### IV Représentation d'un arbre binaire presque complet

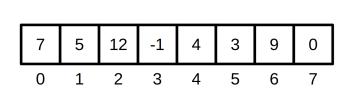
#### Définition 10.3 (Arbre binaire presque complet)

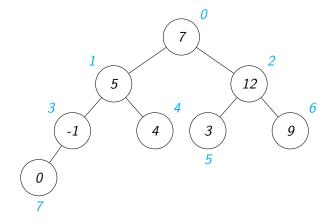
Un arbre binaire presque complet est un arbre binaire dont tous les étages sont remplies sauf éventuellement le dernier qui est alors rempli à gauche

**Principe 10.1** On peut alors représenter un tas par un tableau. On numérote alors les sommets ci contre, donnant l'indice dans le tableau. Les fils du noeuds d'indice i se retrouve aux cases  $2 \times i + 1$ ,  $2 \times i + 2$ , et son père  $\left|\frac{i-1}{2}\right|$ 



#### Exemple 10.5





## 3 Application

Commentaire 10.1 A chaque fois on va écrire en début quelle représentation on utilise pour notre application. Néanmoins, en classe, on pourrait le laisser proposer par les élèves (une fois l'application présentée). On justifie de ce fait notre organisation, ou les applications arrivent toutes ensembles à la fin. (mais on écrit quand même la représentation au début pour que ce soit plus facile de naviguer à la partie que l'on souhaite).

#### I Dictionnaires

**Représentation**: Structure inductive

**Définition 10.4** Un arbre binaire de recherche N(x,G,D) est un arbre binaire de recherche (ABR) si G et D sont des ABR et si, selon un attribut a,  $\max_{u \in G} u.a \le x.a \le \min_{v \in D} v.a$  (avec E qui est un ABR et  $\max_{u \in E} u.a = -\infty$  et  $\min_{u \in E} u.a = +\infty$ )

**Proposition 10.1** Chercher et insérer dans un ABR est en O(h)

**Proposition 10.2** En imposant des contraintes supplémentaires (exemple arbres rouge-noir), on peut forcer  $h = O(\log n)$ 

**Définition 10.5** Un dictionnaire (ou tableau associatif) est un tableau où les indices (clés) ne se limite pas à  $\llbracket 0,n \rrbracket$ 

**Idée 10.2** On peut alors implémenter un dictionnaire par un ABR, les clés étant les étiquettes des nœuds, à condition d'avoir un ordre total sur les clés

**Théorème 10.2** Une implémentation efficace des dictionnaires par ABR permet des opérations de base en  $O(\log n)$ 

Commentaire 10.2 Si on ne veut pas faire le développement 2, et qu'on préfère celui sur les arbres k-dimensionnel, on peut aussi parler aussi du pb des k-plus proches voisins et parler des ABR comme des arbres k-dim pour résoudre le pb

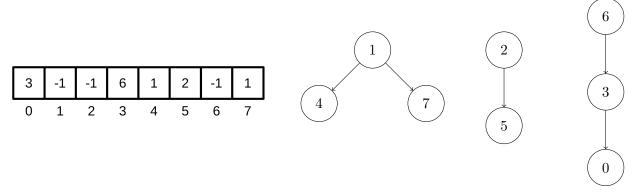
#### II Classes d'équivalence

Représentation : Tableaux

**Définition 10.6** Une structure union & trouver est une structure implémentant les classes d'équivalence, permettant de trouver les représentants d'une classe et d'unir deux classes.

**Idée 10.3** On implémente cette structure sous formes d'un ensemble d'arbres (forêt), où chaque arbre représente une classe et où la racine est le représentant de la classe

**Exemple 10.6** La relation d'égalité modulo 3 sur [0,7] peut être représenté par :



**Proposition 10.3** Si on unifie en faisant pointer la racine de l'arbre le moins profond vers celle de l'arbre le plus profond, on obtient des opérations unir et trouver en  $O(\log(n))$ 

#### III Arbres couvrant de poids minimal

Représentation : liste des arêtes

Définition 10.7 Dans un graphe pondéré connexe, un arbre couvrant de poids minimal, est un sousensemble maximal d'arêtes sans cycles de somme de poids minimal.

Proposition 10.4 En implémentant la détection de cycle par une structure union & trouver, Kruskal renvoie un arbre couvrant de poids minimal en  $O(|L| \times \log |L|)$ 

#### IV Files de priorité

Représentation : celles des arbres semi-complet

**Définition 10.8** Une file de priorité est une séquence de données dont on peut extraire la donnée d'attribut minimum, et rajouter des données.

Idée 10.4 On peut implémenter les files de priorité par des tas min

**Définition 10.9** Un tas min est un arbre semi-complet où chaque noeud a un attribut plus petit que ses fils

Développement 2 : Correction de l'insertion dans un tas min et discussion sur l'implémentation

#### Principe 10.2

- \* Pour ajouter un élément, on le met au bout du tablea et on l'échange avec son père tant qu'il est plus petit
- \* , Pour extraire le min, on met le dernier élément du tableau au début et on l'inverse avec le plus petit de ses fils tant qu'il est plus grand.

**Proposition 10.5** Cette implémentation permet des opérations en  $O(\log n)$ 

**Application 10.1** *Trier par tas en*  $O(n \log n)$ 

# Leçon 11

# Exemples d'algorithmes d'approximation et d'algorithmes probabilistes

Auteur e s: Emile Martinez

Références :

Beaucoup de problèmes sont durs à résoudre. On cherchera alors à sacrifier un peu de la fiabilité du résultat pour gagner en complexité. Il y a deux manières de faire un tel compromis :

- utiliser des algorithmes probabilistes (pouvant prendre beaucoup de temps, ou renvoyer faux)
- n'utiliser des algorithmes ne fournissant que des solutions approchées.

### 1 Algorithmes probabilistes

**Définition 11.1** Un algorithme est déterministe si, pour une entrée x donnée, il s'exécute toujours de la même manière. En particulier, la sortie ne dépend que de l'entrée.

Un algorithme probabiliste est un algorithme dont l'exécution dépend de son entrée x et de valeurs obtenues via un générateur de nombre (pseudo)-aléatoire.

**Exemple 11.1** Recherche dans un tableau T de booléens d'un indice i tel que T[i] == True

Remarque 11.1 Soit p < 1 la proportion de booléen à Faux dans T. Alors l'algo probabiliste se trompe avec une probabilité  $= p^k$ . Pour  $p = \frac{1}{4}$  et k = 5, cela fait  $10^{-3}$ 

#### I Algorithme de type Monte-Carlo

Définition 11.2 Un algorithme probabiliste A pour un pb P est de type Monte-Carlo si pour toute instance i de P,

— A(i) est une solution, erronée avec une certaine probabilité

Le temps d'exécution de A sur i est indépendant des choix aléatoires.

#### **Exemple 11.2** L'algorithme probabiliste de l'exemple 11.1 est de type Monte-Carlo

**Développement 1 :** Vérification probabiliste du produit matriciel

```
Proposition 11.1 (Amplification) Soient 0 < \varepsilon_2 < \varepsilon_1 < 1.
```

S'il existe un algorithme Monte Carlo pour un problème  $\Pi$  ayant une probabilité d'erreur  $\varepsilon_1$ , alors on peut construire un algorithme Monte Carlo pour le problème  $\Pi$  ayant une probabilité d'erreur  $\varepsilon_2$ , en appliquant plusieurs fois l'algorithme initial.

#### Algorithme 11.3 : mediane(L)

```
n \leftarrow |L| L_0 \leftarrow k = n^{\frac{3}{4}} \text{ éléments de } L \text{ aléatoirement} \text{Trier } L_0 x_1 \leftarrow L_0[\frac{k}{2} - \sqrt{n}] x_2 \leftarrow L_0[\frac{k}{2} + \sqrt{n}] L_1 \leftarrow \text{ liste des éléments } < x_1 L_2 \leftarrow \text{ liste des éléments } > x_2 L_3 \leftarrow \text{ liste des éléments } > x_2 \text{si } |L_1| > \frac{n}{2} \text{ ou } |L_3| > \frac{n}{2} \text{ alors} |\text{ retourner } \underline{n'\text{importe quoi}}; \qquad // L_2 \text{ n'a pas capturé la médiane} \text{si } |\underline{L_2}| > n^{\frac{3}{4}} \text{ alors} |\text{ retourner } \underline{n'\text{importe quoi}}; \qquad // \text{ On a trop d'éléments dans } L_2 \text{ pour les trier} \text{Trier } L_2 \text{retourner } \underline{L_2[\frac{n}{2} - |L_1|]}
```

**Idée 11.1** On fait la médiane sur un échantillon de L. Puis on prend tous les éléments autour de cette médiane et on les trie pour trouver la vraie médiane (si elle y est, sinon tant pis).

Commentaire 11.1 Ici le temps dépend du hasard. On considère quand même que c'est un Monte Carlo car c'est borné et prend le temps moyen est un  $\Omega$  du temps dans le pire des cas. On pourrait aussi a la place de retourner n'importe quoi, trier  $n^{3/4}$  éléments et remplir  $L_2$  avec des  $=\infty$  mais alors on complexifie pour rien.

#### II Algorithmes de type Las Vegas

```
Définition 11.3 Un algorithme probabiliste A est de Las Vegas si :

— Si A termine, alors la solution renvoyée est correcte.

— Le temps d'exécution de A est une variable aléatoire.
```

Remarque 11.2 Quand on parle de complexité en moyenne pour un algorithme de Las Vegas, on ne considère pas (ou pas uniquement) la moyenne des complexité sur toutes les entrées possibles prisent uniformément, mais la plus grande espérance du temps d'exécution sur une entrée

#### Algorithme 11.1

### $\textbf{Algorithme 11.4}: tri\_rapide\_randomise(T)$

où partition(T,q) mets dans T, tous les éléments < T[q] puis tous les éléments supérieurs, et renvoie l'indice du milieu.

Remarque 11.3 Le temps d'exécution de l'algorithme 11.1 dépend du choix du pivot :  $O(n^2)$  dans le pire cas,  $O(n \log n)$  dans le meilleur et en moyenne.

Remarque 11.4 Il est possible de transformer un algorithme de type Las Vegas en Monte Carlo en l'exécutant pendant un temps défini et en générant une réponse aléatoire s'il n'a pas terminé.

Remarque 11.5 Si on peut vérifier efficacement la validité du résultat, on peut également faire l'inverse.

**Exemple 11.3** A la place de l'échec dans l'algorithme 26, on peut relancer l'algorithme. On obtient alors un algorithme trouvant toujours la médiane, la calculant en moyenne en 1,5n comparaisons, sans adversaires, ce qui est mieux que tout algorithme déterministe (qui ont nécessairement besoin d'au moins 2n comparaisons en moyenne).

# 2 Algorithmes d'approximation

#### **Définition**

Commentaire 11.2 On peut aussi demander à ce que c soit calculable en temps polynomial mais ce n'est pas nécessaire. Les deux définitions coexistent.

**Remarque 11.6** On se ramène au max en prenant -c.

Définition 11.5 Une  $\lambda$ -approximation est un algorithme polynomial A donnant pour chaque instance i de  $\Pi$  une solution tel que  $\max\left(\left|\frac{A(i)}{OPT(i)}\right|,\left|\frac{OPT(i)}{A(i)}\right|\right) \leq \lambda$ 

#### **II** Exemples

Définition 11.6 (Couvertue par des sommets (Vertex-Cover)) Entrée : Un graphe G=(S,A) Solution : Un ensemble  $S\subset V$  tel que  $\forall u,v\in E,\ v\in S$  ou  $u\in S$ 

```
Algorithme 11.5 : Glouton Vertex Cover
```

```
\begin{split} S \leftarrow \{\} \\ \textbf{tant que} & \text{ il existe une arête } (u,v) \in A \text{ tel que } u \notin S \text{ et } v \notin S \\ & \text{ Choisir } (u,v) \text{ une telle arête} \\ & S \leftarrow S \cup \{(u,v)\} \end{split} \textbf{retourner } S
```

Proposition 11.2 L'algorithme 28 est une 2-approx du problème de la couverture par les sommets.

**Développement :** Une  $\frac{3}{2}$ -approximation et une  $\frac{7}{6}$ -approximation gloutonnes pour le problème d'ordonnancement de tâches indépendantes sur 2 processeurs.

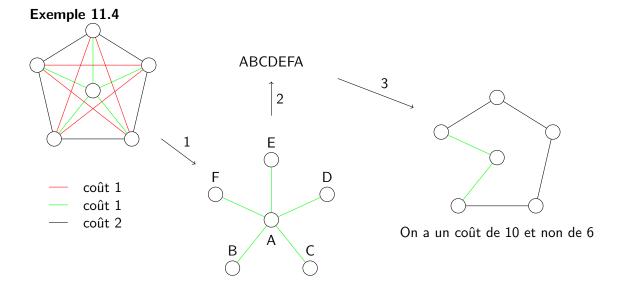
```
Définition 11.7 (Voyageur de commerce (TSP)) Instance : G=(S,A,c) un graphe orienté complet pondéré Solution : Un cycle hamiltonien sur G de poids minimal
```

**Théorème 11.1** Il n'existe pas d'algorithme d'approximation pour TSP, sauf si P = NP.

#### Algorithme 11.2 (Algorithme pour TSP)

- 1.  $A \leftarrow$  arbre couvrant de poids minimal de G
- 2.  $P \leftarrow \text{parcours en profondeur préfixe de } A$
- 3. Renvoyer P

Proposition 11.3 L'algorithme 11.2 est une 2-approx si c vérifie l'inégalité triangulaire  $(\forall x, y, z \in C, c(x, y) + c(y, z) \geq c(x, z))$ 



## 3 Algorithmes d'approximation probabilistes

Il existe des algorithmes d'approximation probabilistes. Ce sont alors souvent des algorithmes de Monte Carlo.

#### I Max Sat

**Définition 11.8** Instance : n variables  $\{x_1, \ldots, x_n\}$ , p clauses  $C_1, \ldots, C_p$  sur  $(x_1, \ldots, x_n)$  contenant au moins k littéraux Solution : Trouver une valuation maximisant le nombre de clauses à vrai

**Exemple 11.5** Si  $\varphi = \bigwedge_{i=1}^{p} C_i$  est satisfiable, une solution optimale est une valuation satisfaisant  $\varphi$ 

Algorithme 11.3 Renvoyer une valuation aléatoire.

Remarque 11.7 On peut créer un algorithme déterministe qui est une  $\left(1-\frac{1}{2^k}\right)$ -approx.

#### II Calcul de $\pi$

On peut calculer une valeur approchée de  $\pi$  par des méthodes probabilistes

Commentaire 11.3 On peut aussi mettre un dessin ici pour expliquer ce qui se passe.

#### Algorithme 11.6 : $calcul\_pi(N)$

```
\begin{array}{c|c} i \leftarrow O \\ \textbf{répéter} \\ & \text{Tirer deux flottants } x,y \text{ dans } [-1,1] \text{ uniformément} \\ \textbf{si } \frac{x^2+y^2<1}{i\leftarrow i+1}; & \text{alors} \\ & \frac{1}{i} \frac{1}{i} \frac{1}{i} \frac{1}{i}; & \text{on a tapé dans le cercle d'aire } \pi \\ \textbf{jusqu'à } \frac{N \text{ fois;}}{N}; & \text{foished the points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{4} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{N} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{N} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{N} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{N} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{N} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise de points dans le cercle / aire du carré} = \frac{\pi}{N} \\ \textbf{retourner} & \frac{\pi}{N}; & \text{otherwise du carré} = \frac{\pi}{N} \\ \textbf{retourner} & \frac
```

Commentaire 11.4 Si on veut parler plus précisément d'algorithme d'approximation, on prendrait dans la def, pour I la manière de représenter les flottants (nb de bits d'exposant, de mentisse, etc. . .) et pour S de tels flottants. La fonction de coût c serait alors la distance à pi (même si pas facilement calculable en temps polynomial)

Remarque 11.8 On peut généraliser la méthode pour le calcul d'intégrales

Remarque 11.9 Cette méthode se généralise en une méthode de Monte Carlo où l'on échantillone le problème, on calcule la solution sur cette échantillon, puis on généralise la solution à partir de cet échantillon.